



ERAD-SE 2025

**Instituto de Computação
UFF - Niterói/RJ, Brasil**

**X Escola Regional de Alto
Desempenho da Região
Sudeste**



Mauro Marques

05-07/11/2025



HPCC
S Y S T E M S

 **LexisNexis**[®]
RISK SOLUTIONS



Processamento e análise de *Big Data* para aplicação de algoritmos de *Machine Learning* com interface *Myriad* através da utilização da plataforma *HPCC Systems*

Minicurso: Objetivo

Processamento e análise de *Big Data* para aplicação de algoritmos de *Machine Learning* com interface *Myriad* através da utilização da plataforma *HPCC Systems*

Objetivo: Ao longo do minicurso, os participantes terão a oportunidade de conhecer os conceitos essenciais de processamento e análise de volumes massivos de dados (*Big Data*) e o processo de desenvolvimento de um serviço de consulta através da utilização da plataforma *open-source* composta por um *Cluster Computacional de Alto Desempenho (HPCC Systems)* e, também, a aplicação de algoritmos de Aprendizado de Máquina com interface *Myriad*, bem como terão a possibilidade de aplicar os conhecimentos adquiridos em um ambiente de treinamento disponibilizado em sala de aula.

Informações Técnicas: Curso de nível básico. O curso requer que a sua realização ocorra em um Laboratório de Informática contendo computadores com acesso à Internet e algum programa para descompactação de arquivos (WinZip/WinRar/7-Zip), também, fazendo-se necessário que os participantes do curso tenham previamente criado uma conta no [Github](#).

Minicurso: Autor



- **Mauro Marques** – Engenheiro de SW na LexisNexis Risk Solutions
Engenheiro com pós-graduação nas áreas de TI e Educação
39 anos de atuação como engenheiro nos setores automobilístico e de TI
13 anos de atuação como professor universitário nas áreas de Engenharia e Ciência da Computação
Mauro.Marques@lexisnexisrisk.com

Redes sociais:

youtube.com/user/HPCCsystems
hpccsystems.com/

Minicurso: Agenda

➤ LexisNexis Risk Solutions: A Empresa

- Quem somos nós?
- A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

➤ HPCC Systems: Visão Geral

- Apresentação de conceitos;
- Aplicação de conhecimentos;
- Desenvolvimento de um serviço de consulta;
- Utilização de algoritmos de Aprendizado de Máquina.

➤ Atividades de treinamento

- Cursos *online*;
- Projetos de pesquisa;
- Oportunidades profissionais.

➤ Considerações Finais

Minicurso: Agenda

➤ LexisNexis Risk Solutions: A Empresa

- Quem somos nós?
- A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

➤ HPCC Systems: Visão Geral

- Apresentação de conceitos;
- Aplicação de conhecimentos;
- Desenvolvimento de um serviço de consulta;
- Utilização de algoritmos de Aprendizado de Máquina.

➤ Atividades de treinamento

- Cursos *online*;
- Projetos de pesquisa;
- Oportunidades profissionais.

➤ Considerações Finais

LexisNexis Risk Solutions: A Empresa

■ Quem somos nós?

A **LexisNexis Risk Solutions** é líder no fornecimento de informações essenciais que ajudam clientes de diversos setores e governos na avaliação, prevenção e gestão de riscos.

Fazemos parte de um grupo contendo um portfólio de marcas, abrangendo vários setores que fornecem aos clientes tecnologias inovadoras, análises baseadas em informações e ferramentas de decisão e serviços de dados.

Minicurso: Agenda

➤ LexisNexis Risk Solutions: A Empresa

- ✓ Quem somos nós?
- A nossa tecnologia: A evolução da plataforma *HPCC Systems...*

➤ HPCC Systems: Visão Geral

- Apresentação de conceitos;
- Aplicação de conhecimentos;
- Desenvolvimento de um serviço de consulta;
- Utilização de algoritmos de Aprendizado de Máquina.

➤ Atividades de treinamento

- Cursos *online*;
- Projetos de pesquisa;
- Oportunidades profissionais.

➤ Considerações Finais

Histórico: A plataforma *HPCC Systems*

■ A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

2001



Primeira versão
da plataforma
HPCC é lançada

2011



Código aberto
(licença Apache e
código no GitHub)

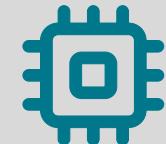
2012 - 16



Melhorias contínuas
com **FOCO NA
QUALIDADE**

Supporte e
treinamento
aprimorado

2017-Presente



Aprimoramentos de
arquitetura (*Cloud*)
Desenvolvimentos em
Machine Learning

Minicurso: Agenda

✓ LexisNexis Risk Solutions: A Empresa

- ✓ Quem somos nós?
- ✓ A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

➤ ***HPCC Systems: Visão Geral***

- Apresentação de conceitos;
- Aplicação de conhecimentos;
- Desenvolvimento de um serviço de consulta;
- Utilização de algoritmos de Aprendizado de Máquina.

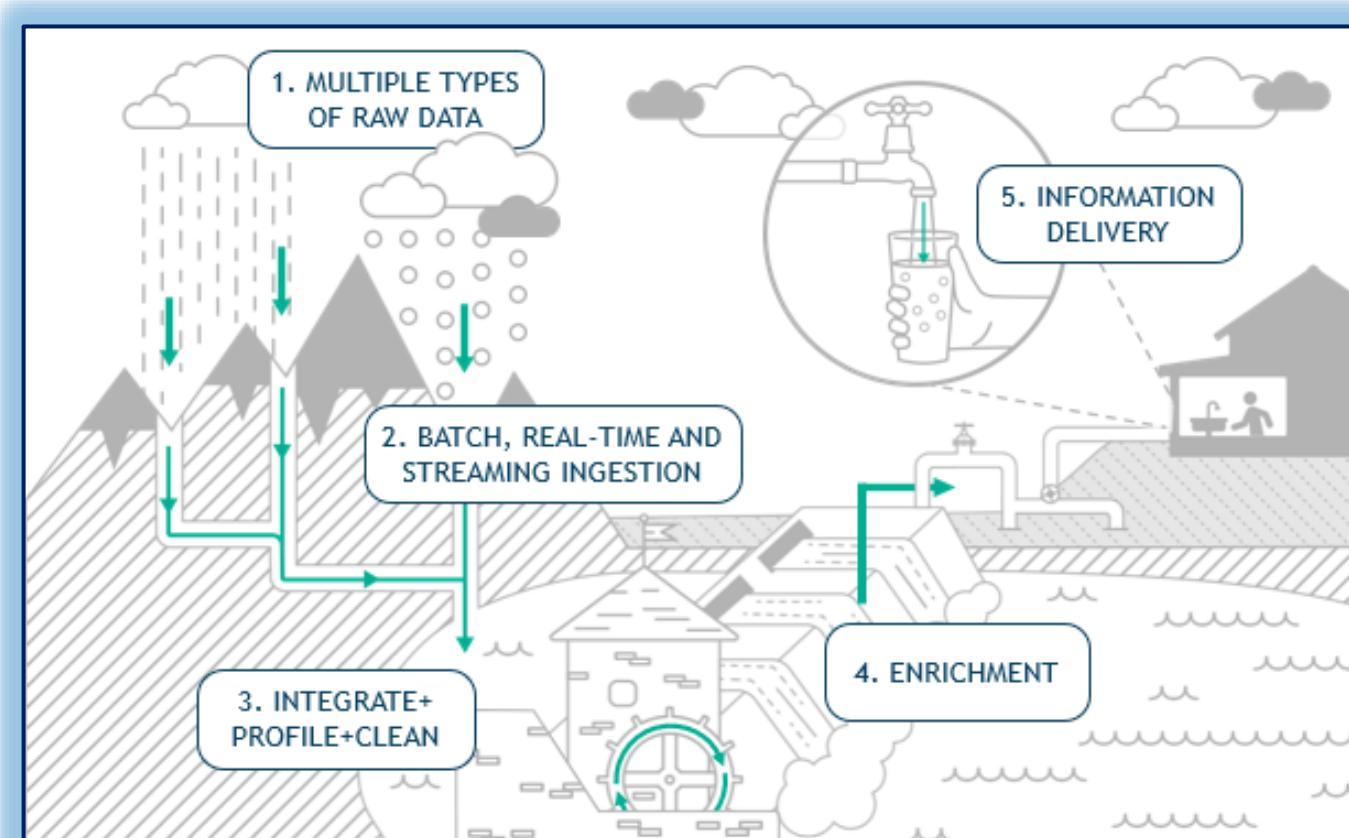
➤ **Atividades de treinamento**

- Cursos *online*;
- Projetos de pesquisa;
- Oportunidades profissionais.

➤ **Considerações Finais**

HPCC Systems: Visão geral

■ Apresentação de conceitos

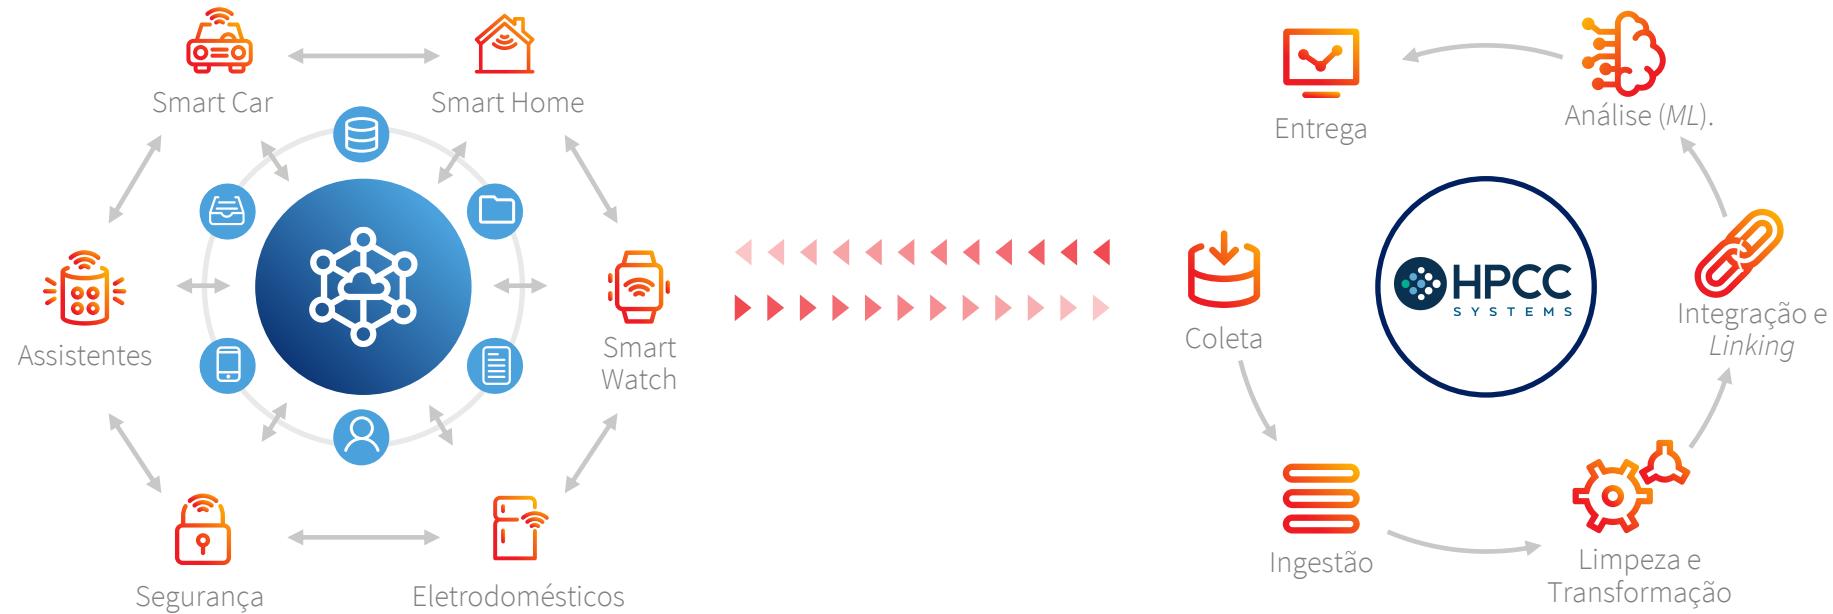


<https://youtu.be/FDuCuDRy1wU>

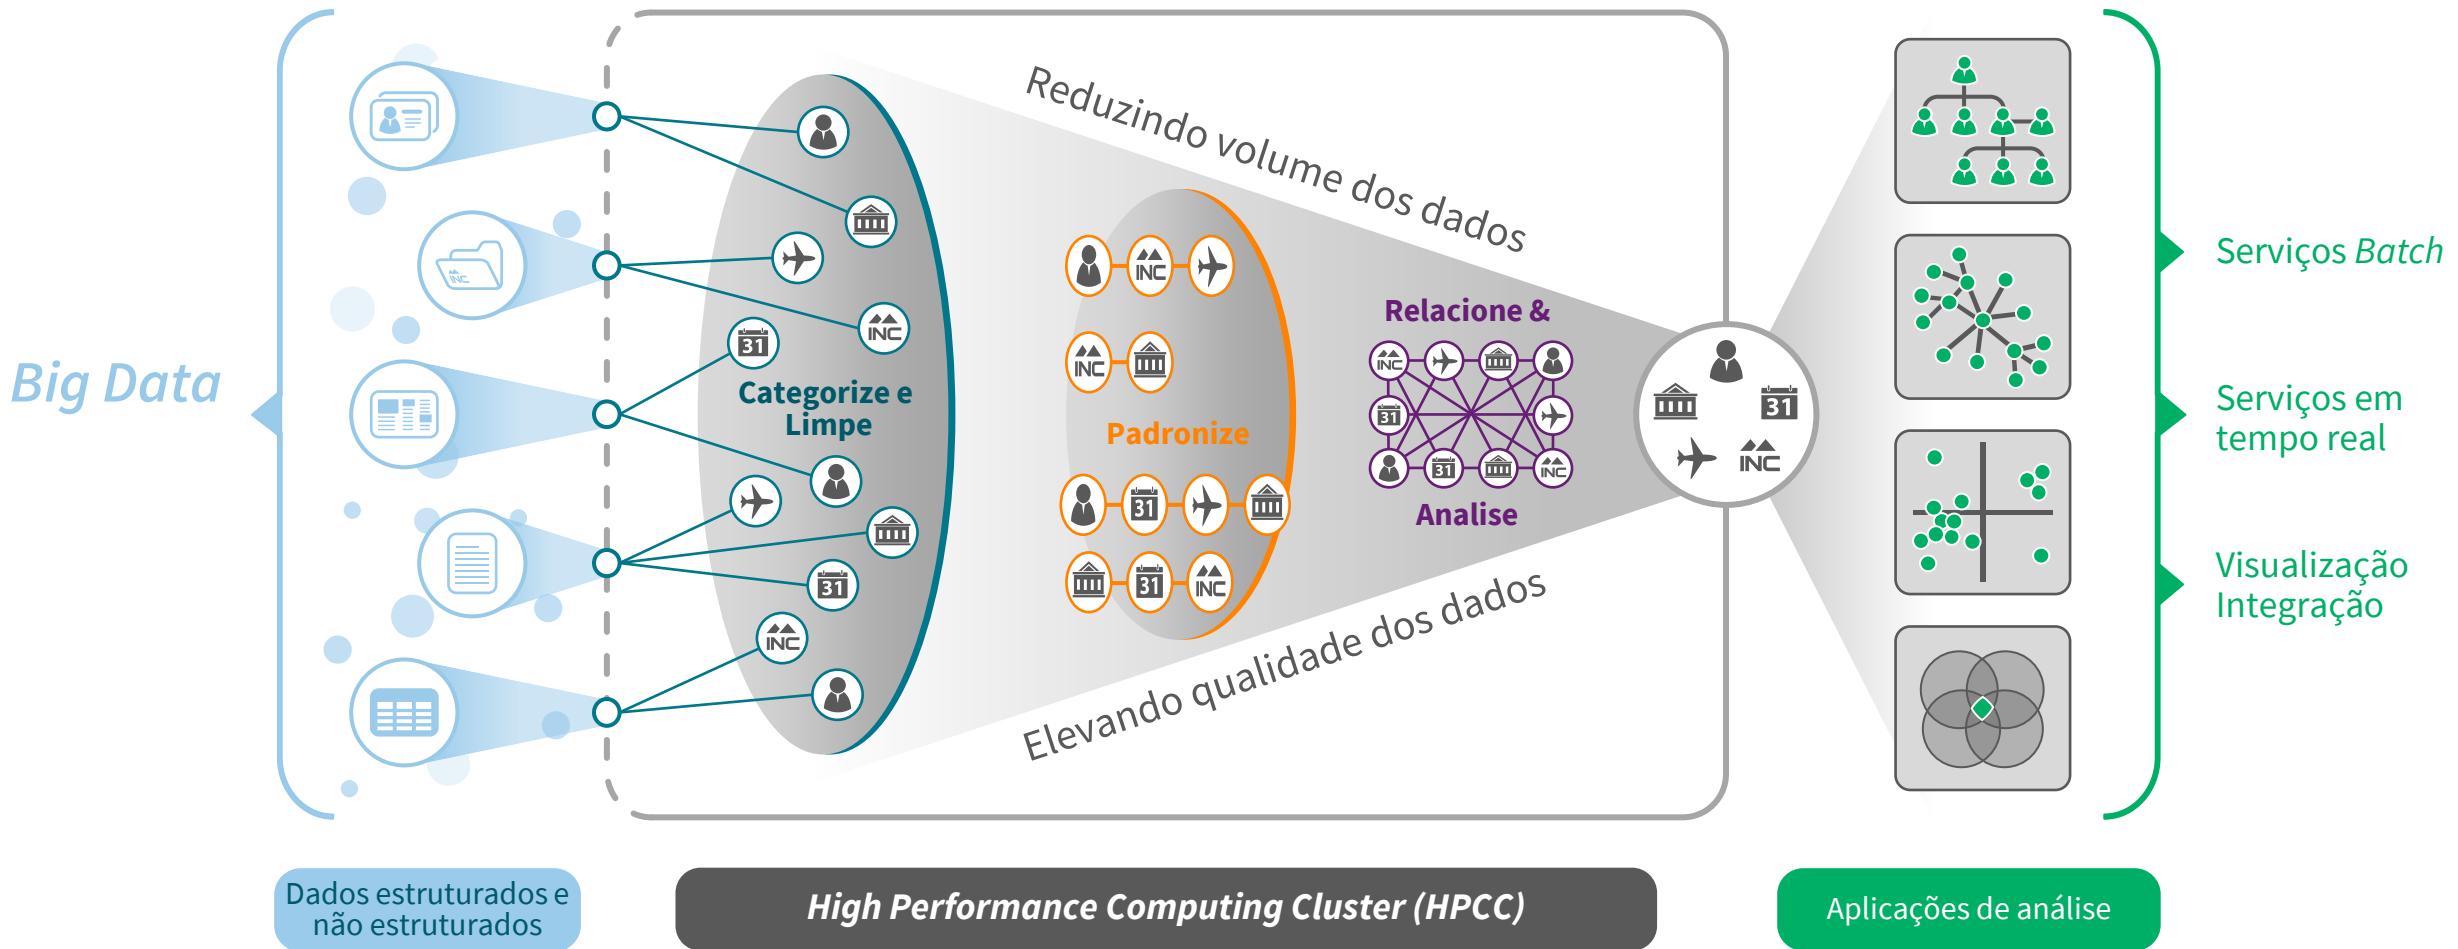
HPCC Systems

Processamento e Análise de *Big Data*

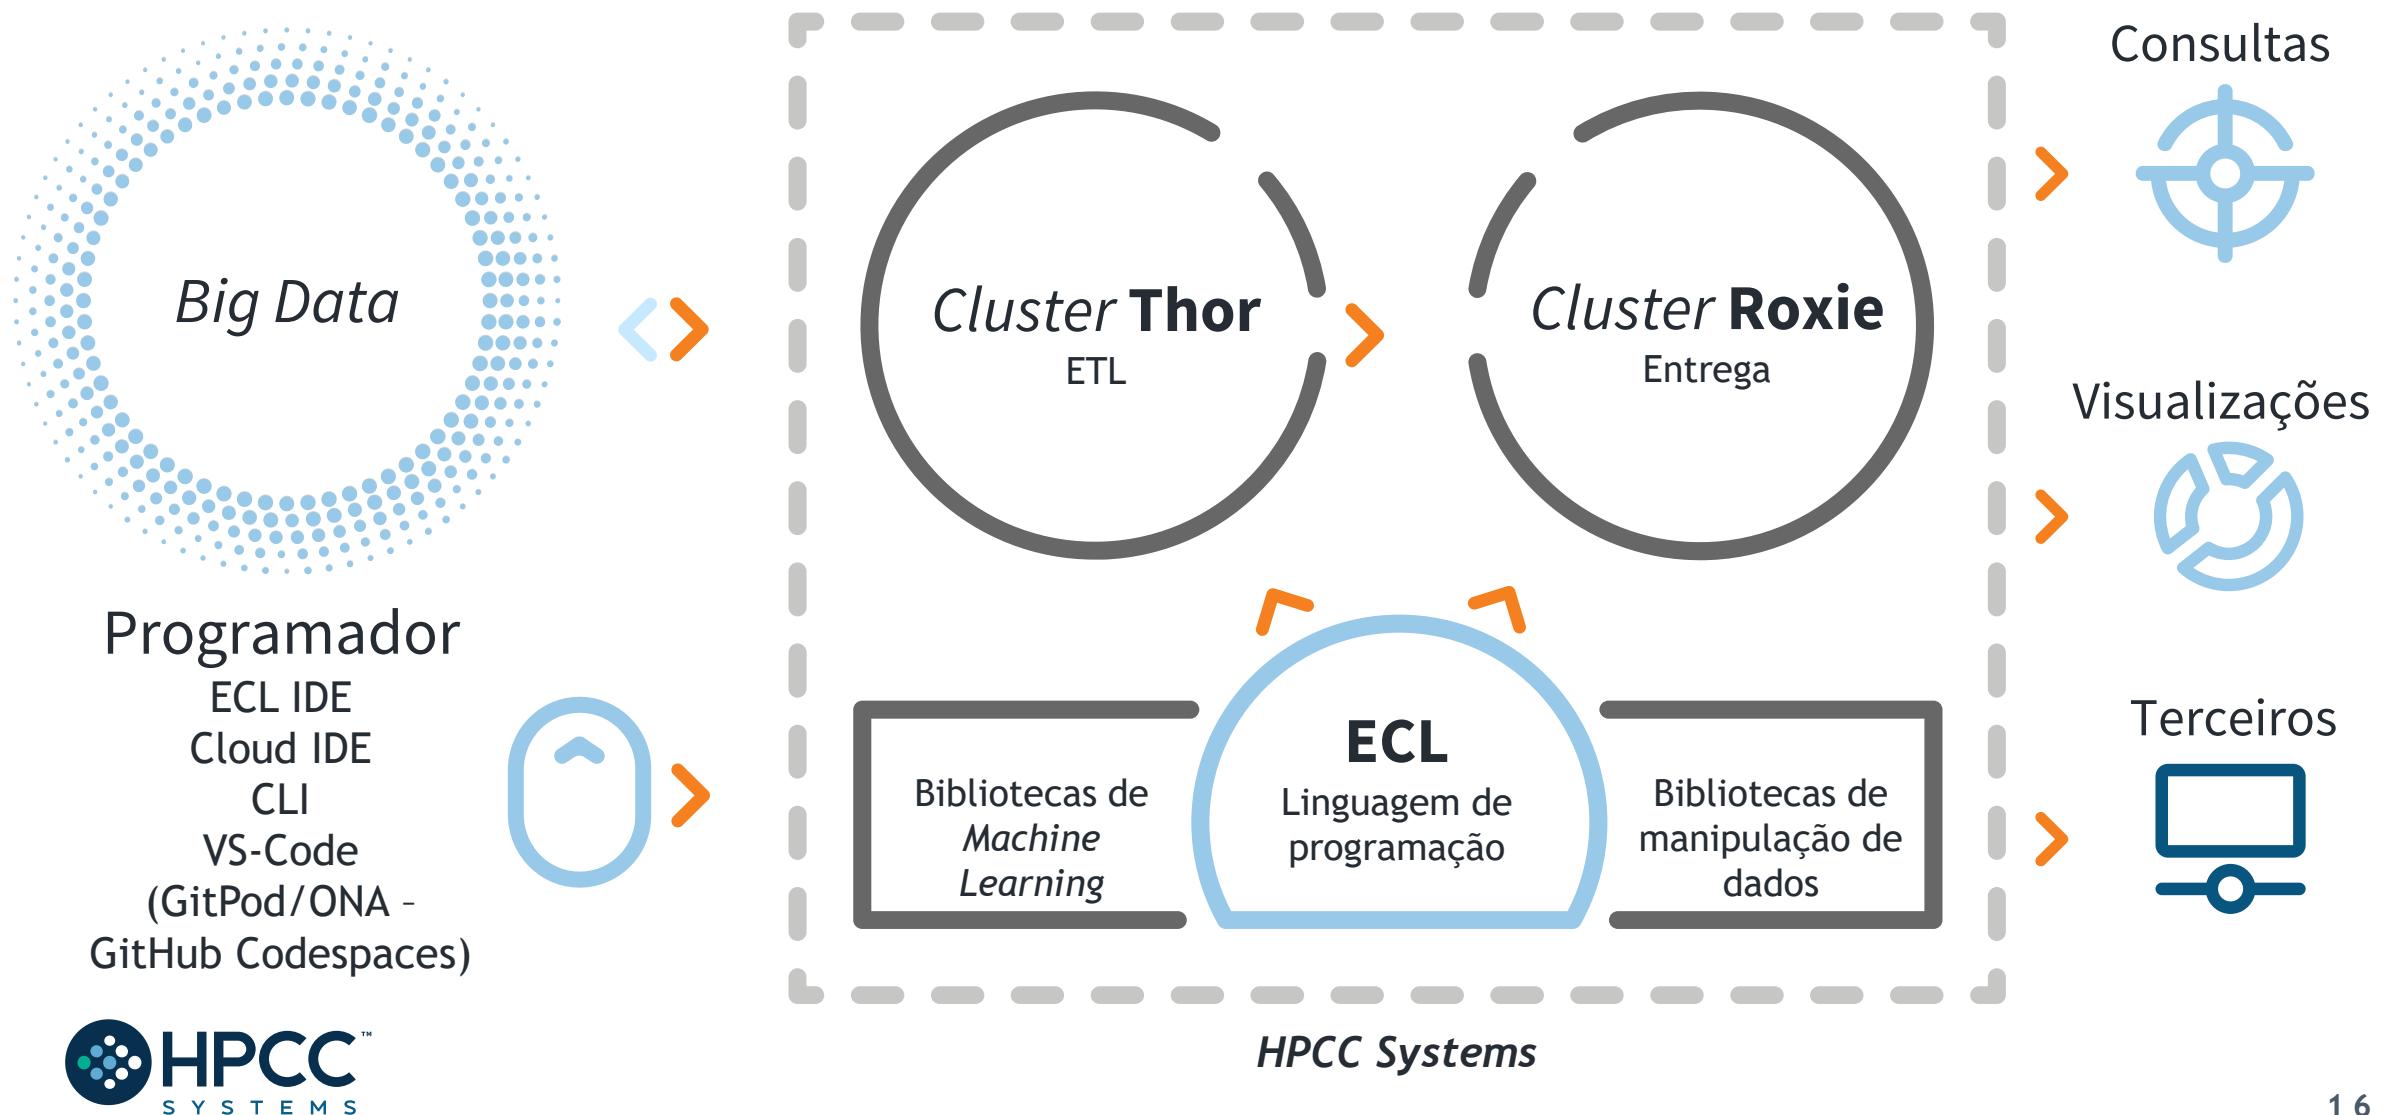
Como trabalha a plataforma *HPCC Systems*?



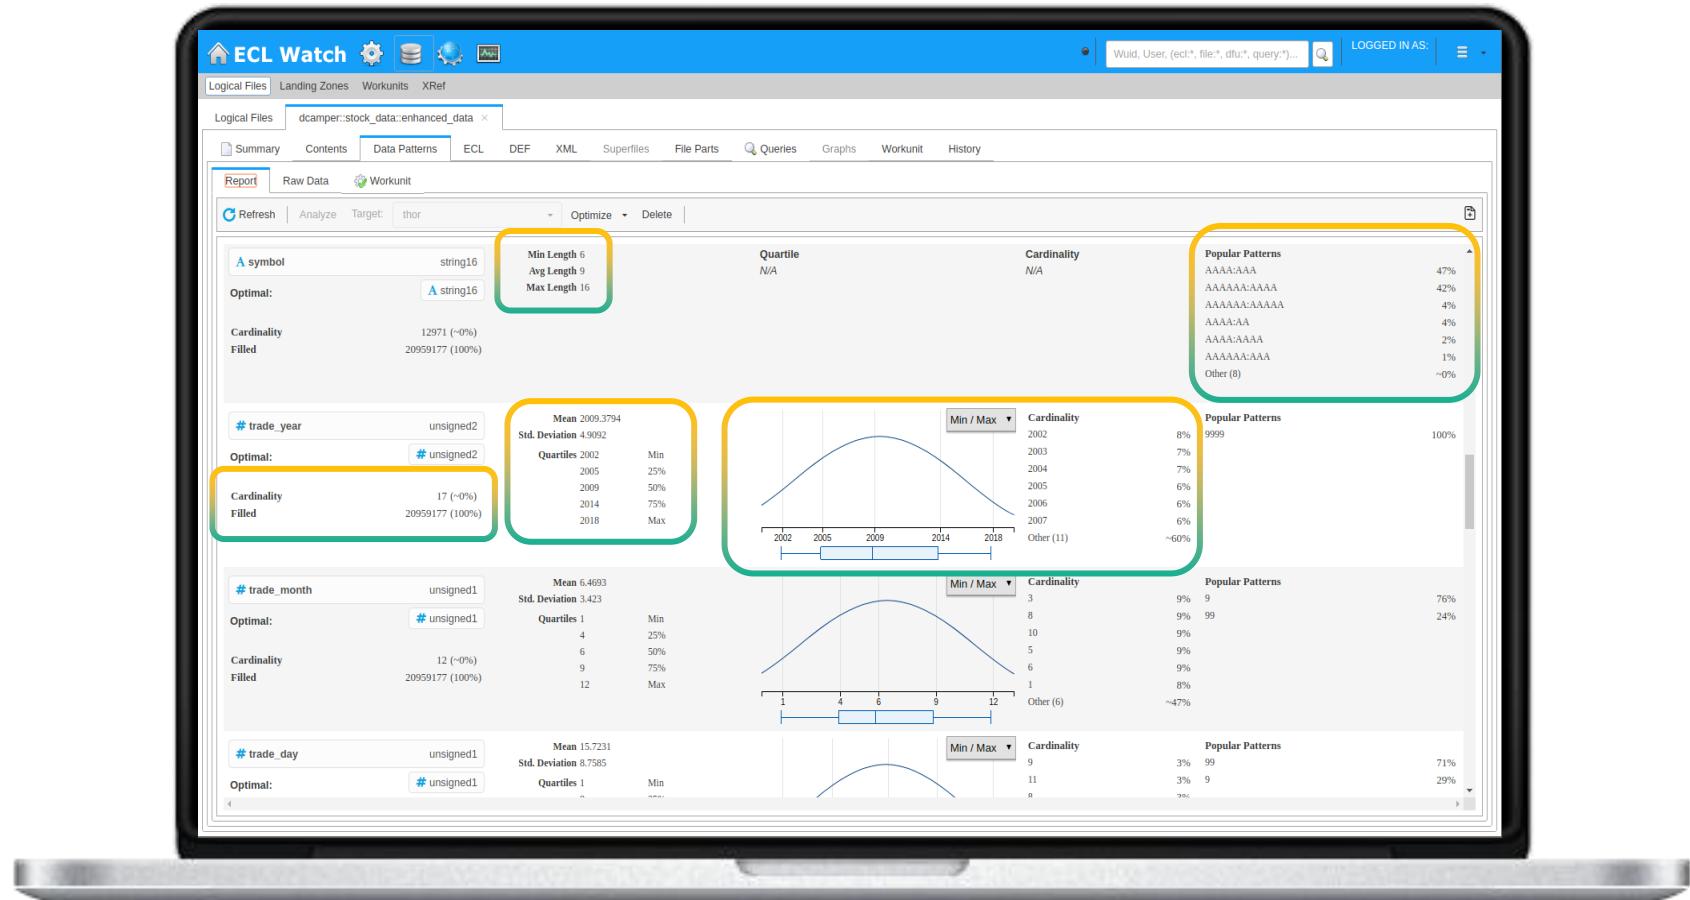
Fluxo de dados no HPCC Systems: “Funil” de dados



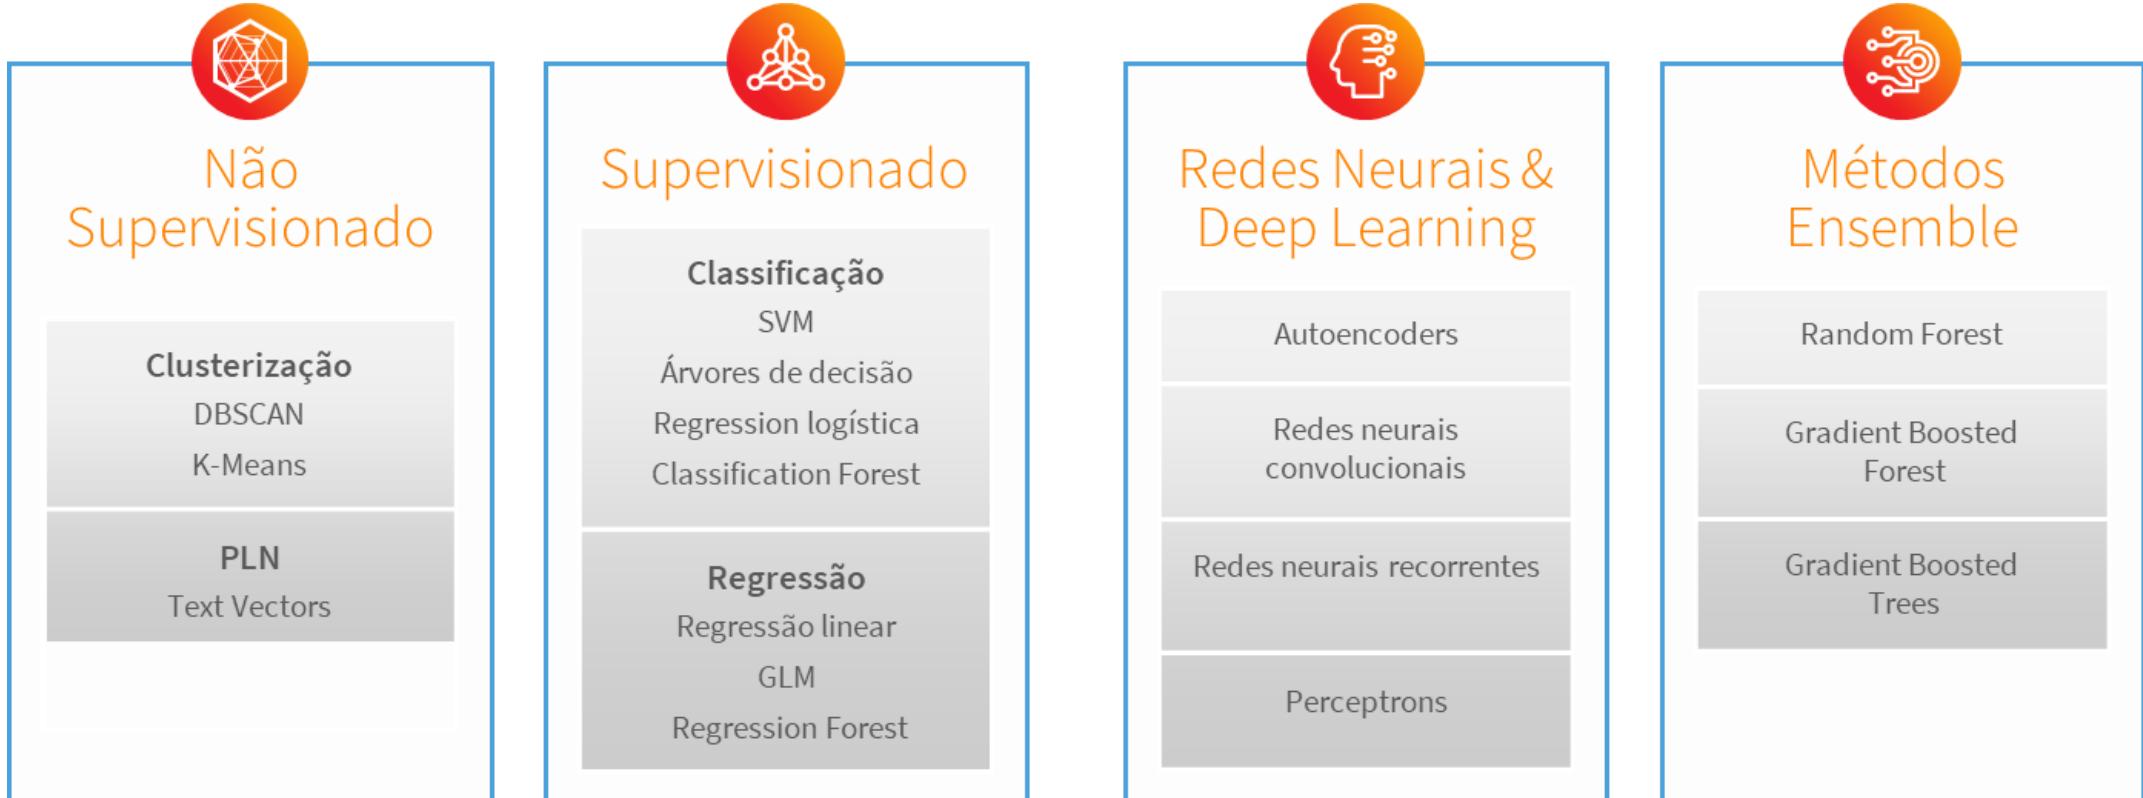
Arquitetura da plataforma *HPCC Systems*



Bibliotecas de perfilamento de dados – “Profiling”



Bibliotecas de “Machine Learning”



Minicurso: Agenda

✓ LexisNexis Risk Solutions: A Empresa

- ✓ Quem somos nós?
- ✓ A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

➤ ***HPCC Systems: Visão Geral***

- ✓ Apresentação de conceitos;
- Aplicação de conhecimentos;
- Desenvolvimento de um serviço de consulta;
- Utilização de algoritmos de Aprendizado de Máquina.

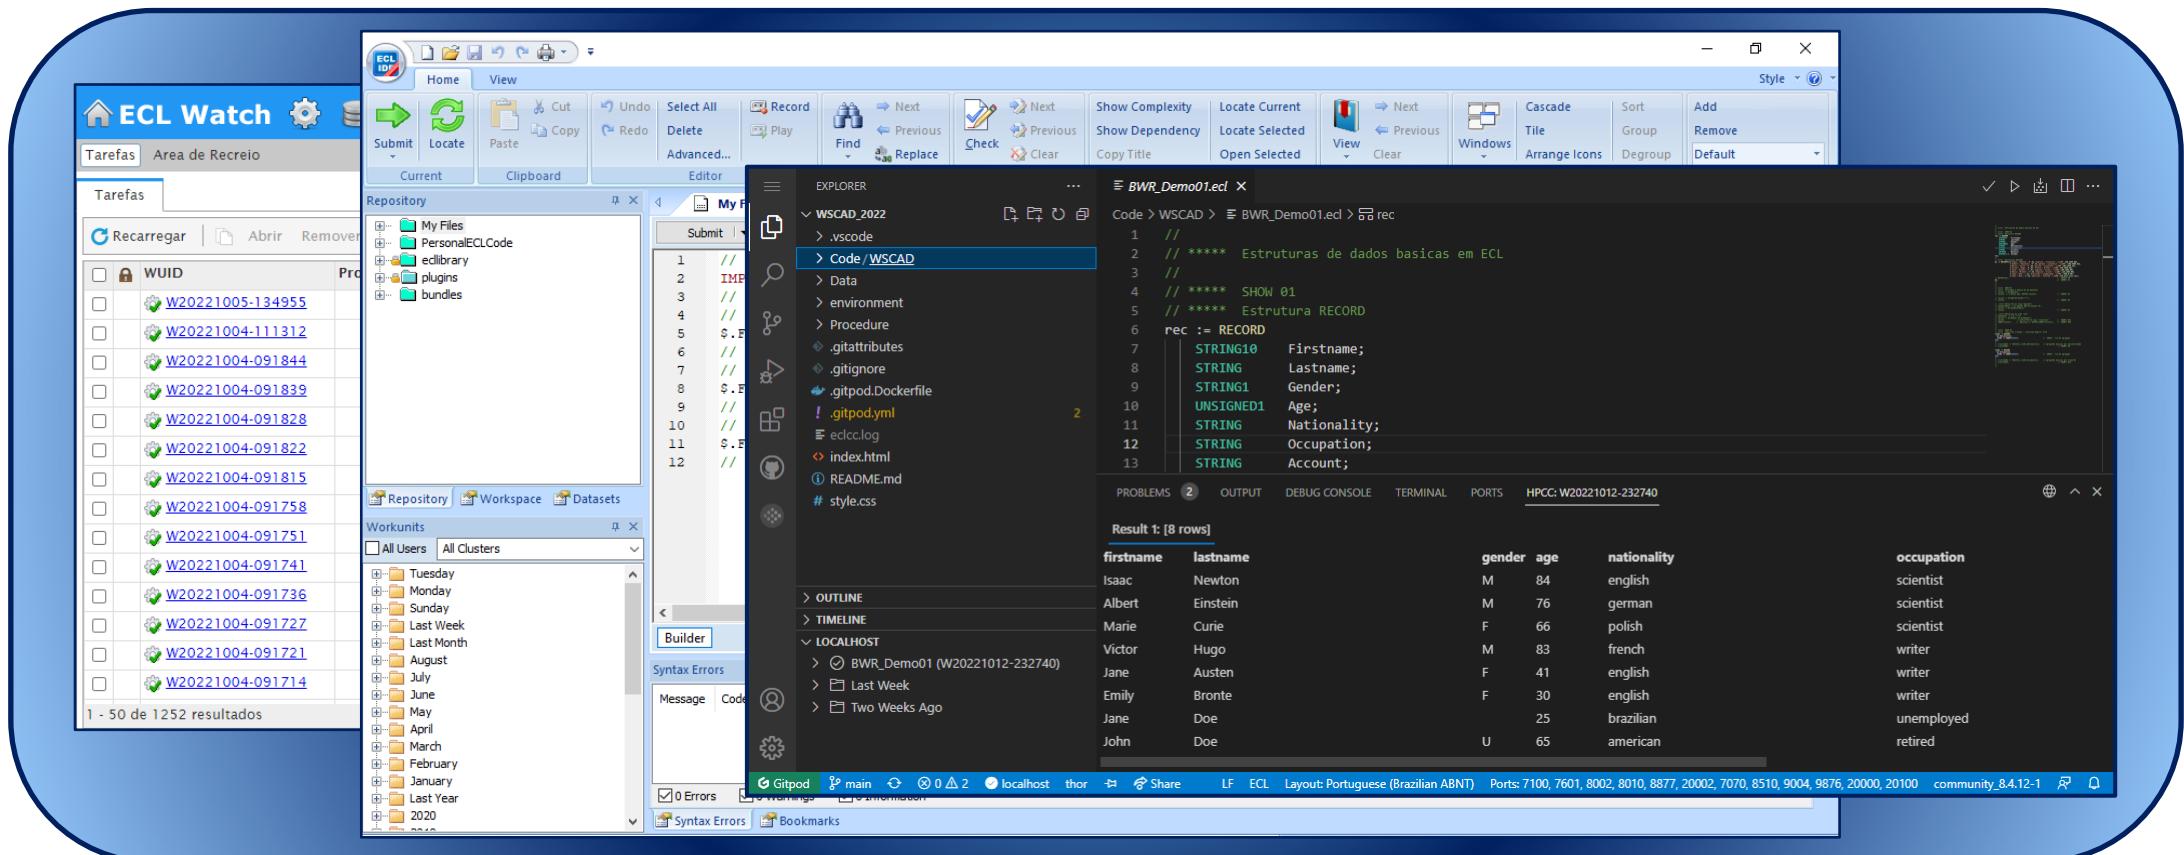
➤ **Atividades de treinamento**

- Cursos *online*;
- Projetos de pesquisa;
- Oportunidades profissionais.

➤ **Considerações Finais**

HPCC Systems: Visão geral

■ Aplicação de conhecimentos

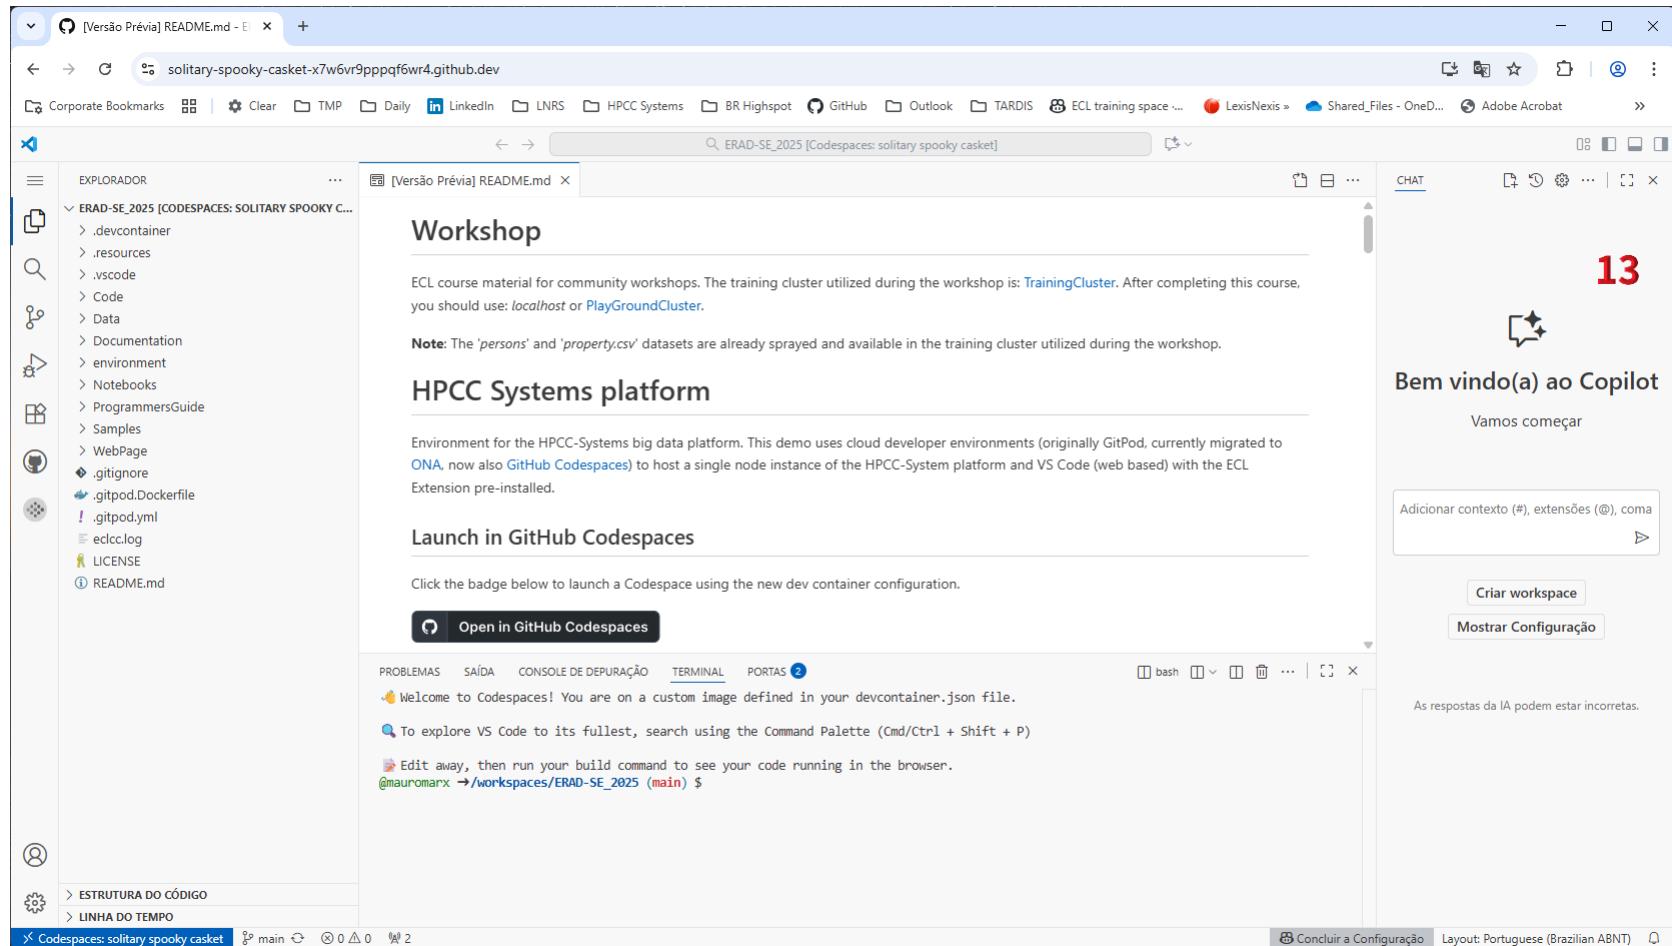


A) Configuração do ambiente: *Github Codespaces com “Fork”*

The image is a collage of screenshots illustrating the process of setting up a GitHub Codespace environment using a fork. The steps are numbered 1 through 12.

- Sign in to GitHub**: Shows the GitHub sign-in page with a red box around the GitHub logo.
- mauromarx profile**: Shows the GitHub profile for user mauromarx with a red box around the GitHub icon.
- Wikis**: Shows the GitHub Wikis section with a red box around the GitHub icon.
- 1 user**: Shows the GitHub user list with a red box around the GitHub icon.
- Popular repositories**: Shows the GitHub repository search results for "WSCAD_2022" with a red box around the GitHub icon.
- Your existing forks**: Shows the GitHub "Your existing forks" page with a red box around the GitHub icon.
- Create a fork**: Shows the GitHub "Create a fork" dialog with a red box around the GitHub icon.
- Recent Repositories**: Shows the GitHub recent repositories page with a red box around the GitHub icon.
- Code editor interface**: Shows the GitHub code editor interface with a red box around the GitHub icon.
- README and license**: Shows the GitHub README and Apache-2.0 license page with a red box around the GitHub icon.
- Launch in GitHub Codespaces**: Shows the GitHub "Launch in GitHub Codespaces" button with a red box around the GitHub icon.
- Create a new codespace**: Shows the GitHub "Create a new codespace" dialog with a red box around the GitHub icon.

A) Configuração do ambiente: *Github Codespaces* com “Fork”



B) Enterprise Control Language (ECL)

■ Conceitos básicos de ECL:

- Paradigma declarativo (não-procedural)
- ECL não é sensível a caixa alta/baixa
- Espaço em branco é ignorado para melhor leitura
- Comentários em linha (//) e em bloco (/* e */)
- ECL utiliza sintaxe **objeto.propriedade**

Dataset.Campo // referenciando um campo em um *dataset*

NomedoDiretorio.Definicao // referenciando uma definição em outro módulo

B) Enterprise Control Language (ECL)

✓ O código ECL é constituído de Definições e Ações

✓ Definições estabelecem *o que* as coisas são, não *como* fazê-las
(arquivos de definição ECL)

```
MyDef := 'Hello World';                                // não inicia uma WU
```

✓ Ações em ECL resultam em compilação e execução
(arquivos BWR)

```
OUTPUT(MyDef);                                     // inicia uma WU
OUTPUT('Hello World, again...');                   // inicia uma WU
```

B) Enterprise Control Language (ECL)

- “*Inline*” datasets utilizados durante a primeira parte da demonstração:

Firstname	Lastname	Gender	Age	Nationality	Occupation	Account	Balance	Income
Isaac	Newton	M	84	english	scientist	cc100	100	3500.00
Albert	Einstein	M	76	german	scientist	cc200	-100	4000.30
Marie	Curie	F	66	polish	scientist	cc300	200	3640.10
Victor	Hugo	M	83	french	writer	cc400	150	1900.00
Jane	Austen	F	41	english	writer	cc500	180	2000.00
Emily	Bronte	F	30	english	writer	cc600	120	1800.00
Jane	Doe		25	brazilian	unemployed	cc700	-500	0.00
John	Doe	U	65	american	retired	cc800	750	3211.11

Firstname	Lastname	Email	Phone
ISAAC	NEWTON	isaac.newton@cam.ac.uk	16431727
ALBERT	EINSTEIN	albert.einstein@princeton.edu	18791955
MARIE	CURIE	marie.curie@sorbonne.fr	18671934
VICTOR	HUGO	victor.hugo@lacroix.fr	18021885
JANE	AUSTEN	jane.austen@hampshire.uk	17751817
EMILY	BRONTE	emily.bronte@thornton.uk	18181848
JANE	DOE	jane.doe@hotmail.com	
JOHN	WAYNE	john.wayne@paramount.com	12345678

B) Enterprise Control Language (ECL)



A screenshot of a GitHub Codespaces environment running in a Microsoft Visual Studio Code interface. The left sidebar shows a file tree for a project named 'WSCAD_2022' containing files like '.vscode', 'Code/WSCAD', 'Data', 'environment', 'Procedure', '.gitattributes', '.gitignore', '.gitpod.Dockerfile', '.gitpod.yml', 'eclcc.log', 'index.html', 'README.md', and 'style.css'. The main editor window displays an ECL (Enterprise Control Language) script named 'BWR_Demo01.ecl'. The code defines a record structure 'rec' with fields: Firstname, Lastname, Gender, Age, Nationality, Occupation, and Account. Below the code, a table titled 'Result 1: [8 rows]' shows data from the script execution:

firstname	lastname	gender	age	nationality	occupation
Isaac	Newton	M	84	english	scientist
Albert	Einstein	M	76	german	scientist
Marie	Curie	F	66	polish	scientist
Victor	Hugo	M	83	french	writer
Jane	Austen	F	41	english	writer
Emily	Bronte	F	30	english	writer
Jane	Doe		25	brazilian	unemployed
John	Doe	U	65	american	retired

The bottom of the screen shows the GitHub Codespaces interface with tabs for PROBLEMS, OUTPUT, DEBUG CONSOLE, TERMINAL, PORTS, and HPCC: W20221012-232740. The footer includes icons for Gitpod, main, localhost, thor, Share, LF, ECL, Layout: Portuguese (Brazilian ABNT), Ports: 7100, 7601, 8002, 8010, 8877, 20002, 7070, 8510, 9004, 9876, 20000, 20100, community_8.4.12-1, and a few other small icons.

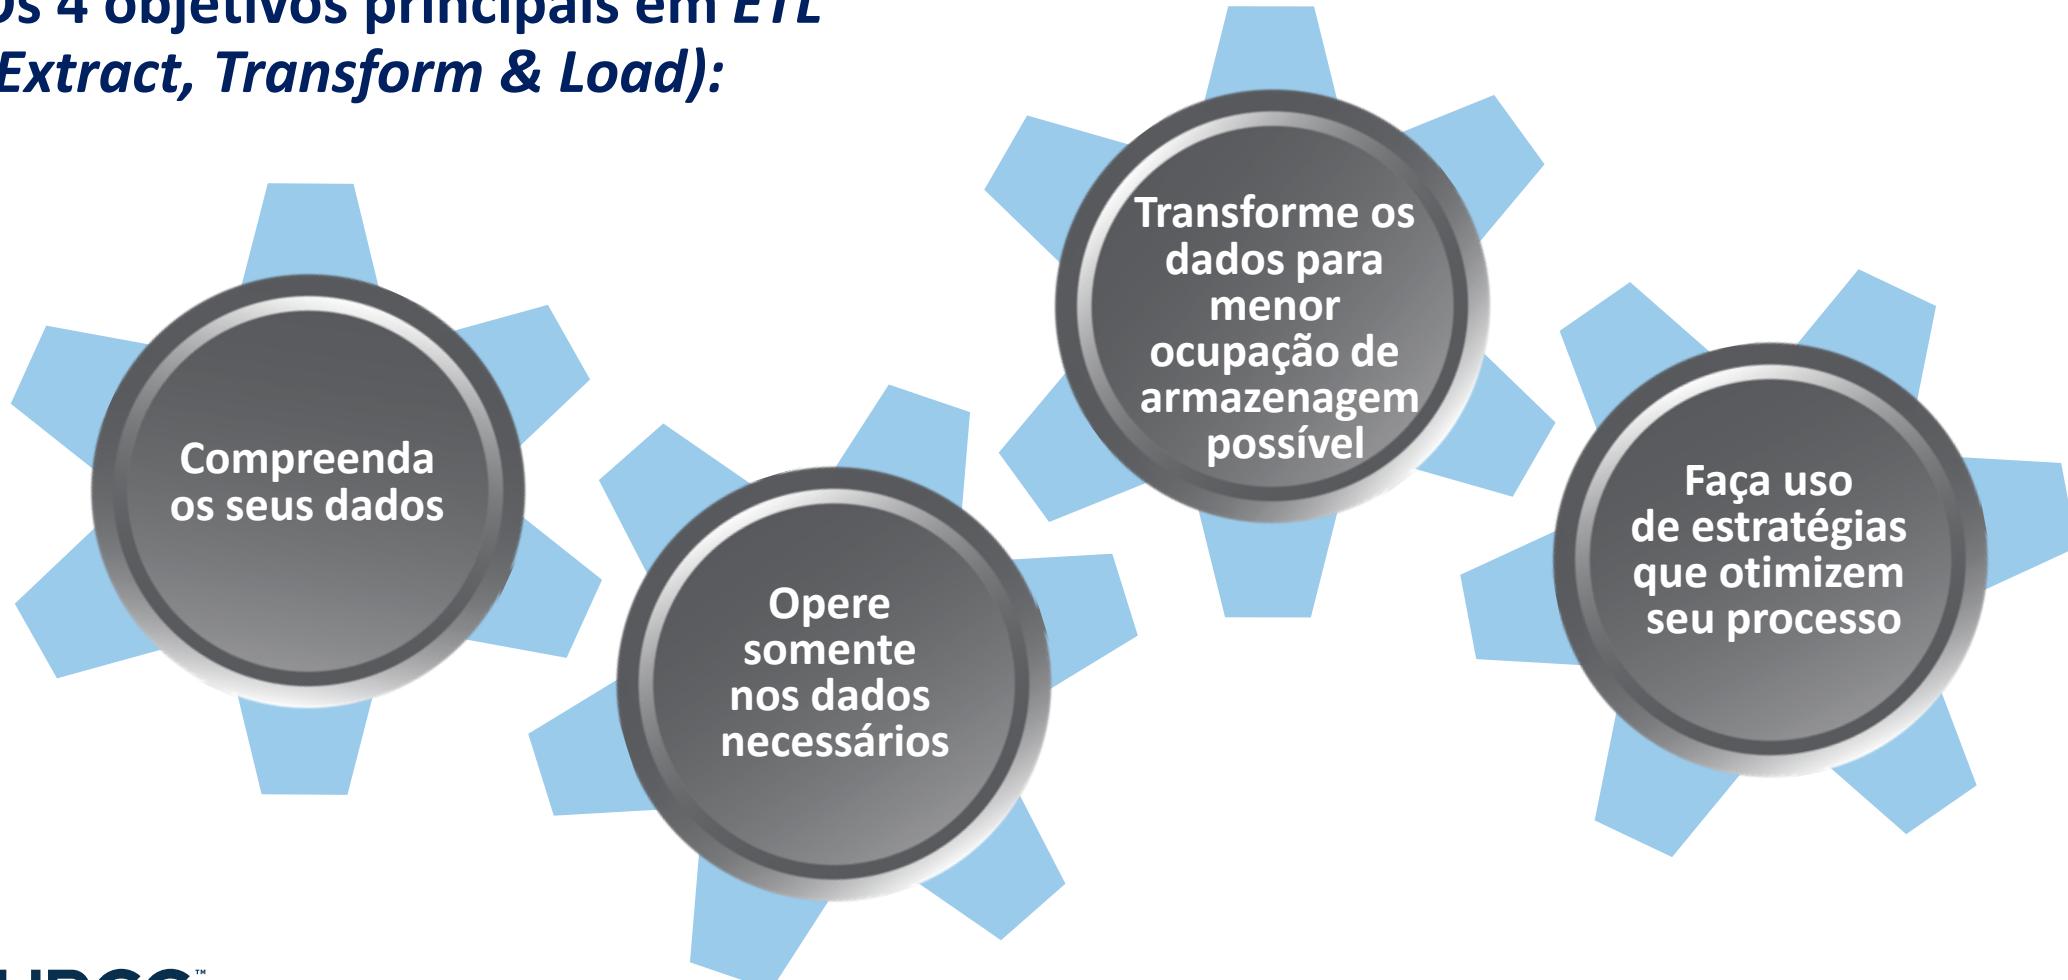
RoadMap 01 - Sequência dos códigos ECL:

Demonstração - ECL codes (*Target* = Thor):

1. BWR_Tests.ecl (submit)
2. Demo00.ecl (submit)
3. Demo01.ecl (submit)
4. Demo02.ecl (submit)
5. Demo03.ecl (submit)
6. Demo04.ecl (submit)
7. Demo05.ecl (submit)
8. modInline01.ecl
9. modInline02.ecl
10. BWR_BrowseData01.ecl (submit)

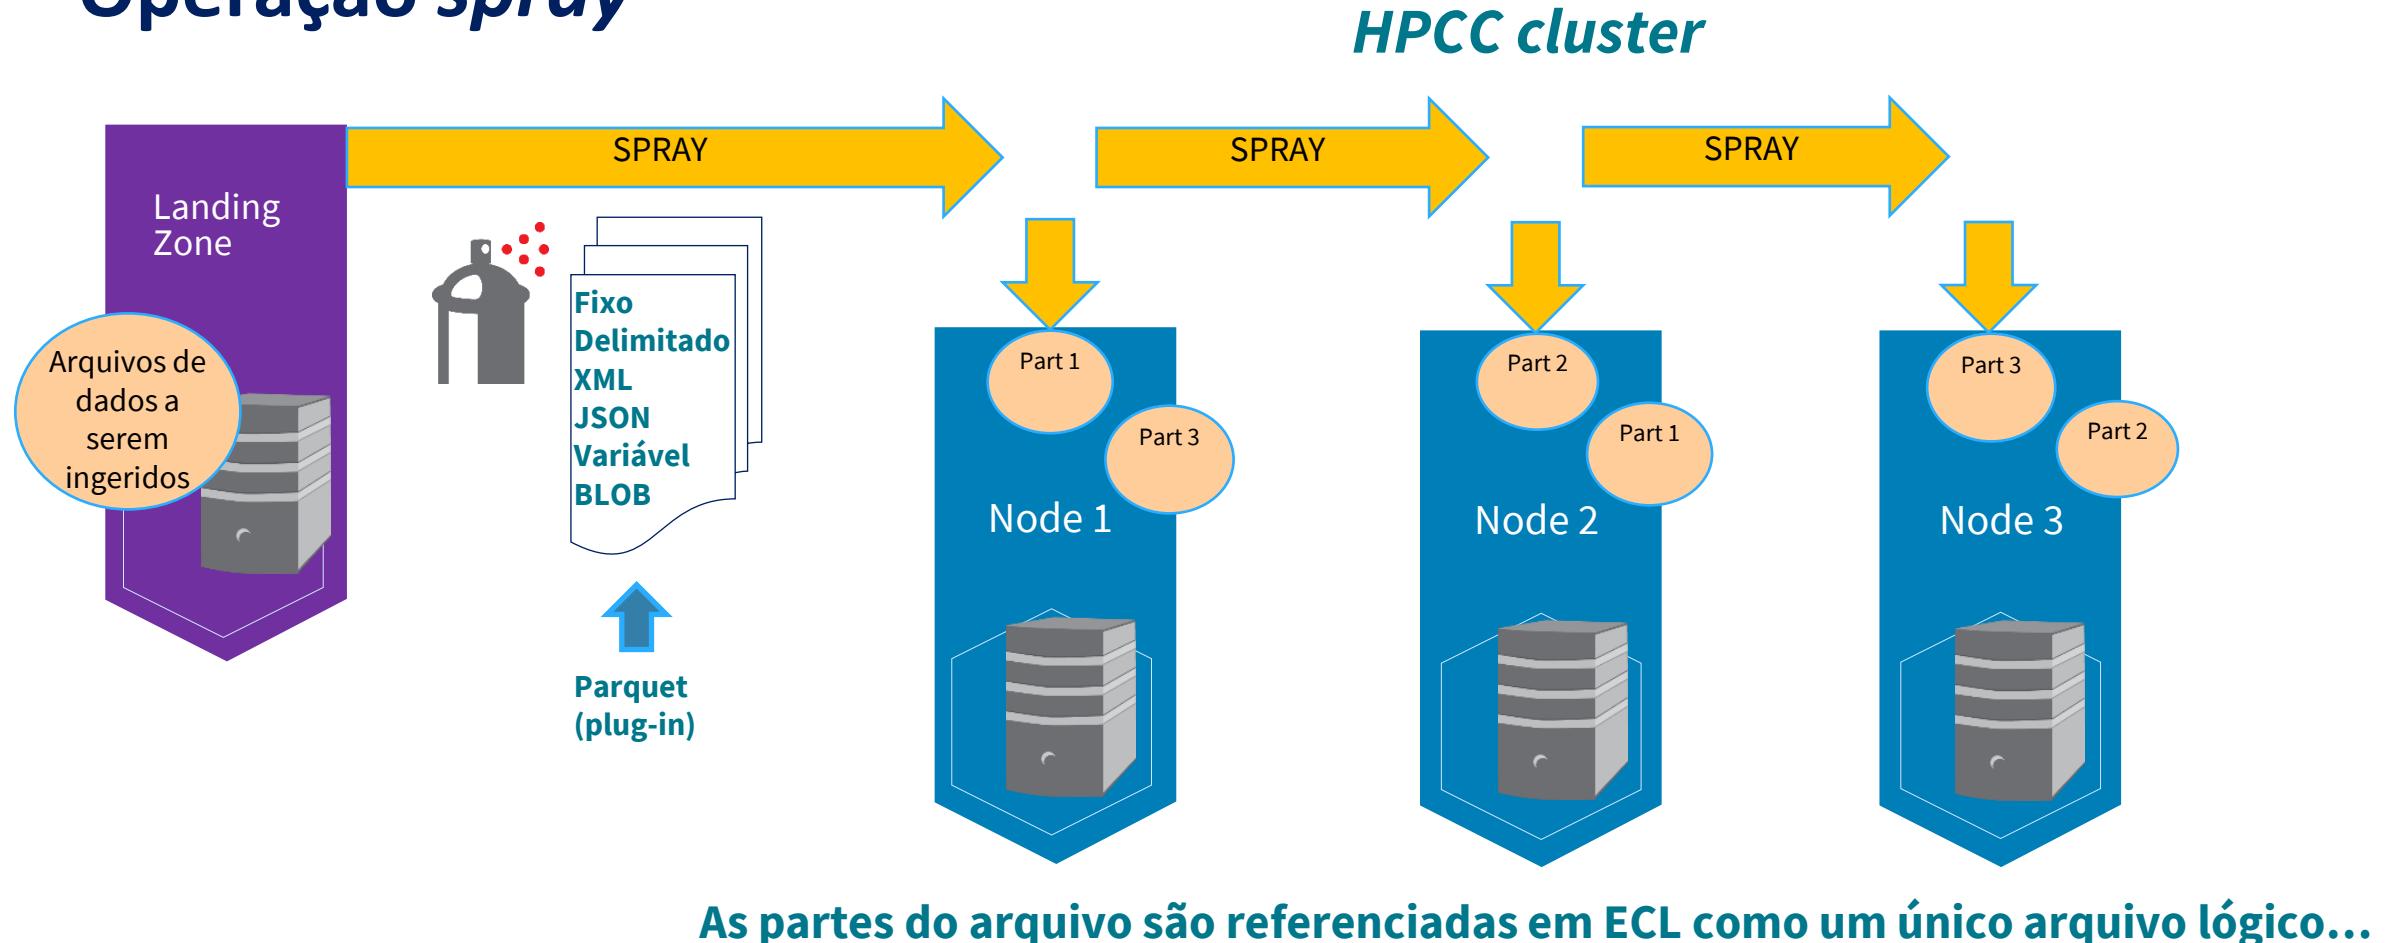
C) ETL - Extract, Transform & Load

- Os 4 objetivos principais em *ETL* (*Extract, Transform & Load*):



C) Extração dos dados

- Operação *spray*



C) Extração dos dados

■ Escopo e nomes de arquivos lógicos

Nomes de arquivos sempre começam com um escopo (estrutura de diretórios) e terminando com o nome do arquivo.

- O HPCC busca por arquivos cujos nomes começam com um escopo padrão (THOR):
`'DIR1::DIR2::NomeArquivo'` //dado isso, HPCC procura por:
`'THOR::DIR1::DIR2::NomeArquivo'` //esse arquivo
- O sinal de “til” (~) indica a supressão do escopo padrão:
→ `'~DIR1::DIR2::NomeArquivo'` //dado isso, HPCC procura por:
`'DIR1::DIR2::NomeArquivo'` //esse arquivo

C) Extração dos dados

- **Upload do “raw” dataset para a ‘Zona de Entrada de Arquivos’:**
 - Importação dos Dados Brutos (Upload = *Landing Zone*)



C) Extração dos dados

- **Spray para a distribuição do arquivo entre os ‘nós’ do Cluster:**
 - Spray do arquivo (Spray = *Logical Files*)

Spray (Distribuir aos Nós): Fixo ▾ Delimitado ▾ XML ▾ JSON ▾ Variável ▾ BLOB ▾

Destino

Grupo: mythor
Fila: dfuserver_queue
Escopo de Destino: CLASS::MDM::DEMO::
Nome do Destino: DatasetInline01

Opções

Formato: ASCII
Maximo tamanho do registro: 8192
Separadores: \,
Omitir Separador:
Escapar:
Terminador de linhas: \r\n\r\n
Aspas: "
Sobreescriver: Replicar:
Sem Separador: Incomum:
Compactar: Falha em caso de arquivo sem fonte:
Estrutura de registro disponível: Terminador em Aspas:
Expira em (dias): Replicação atrasada:

Spray (Distribuir aos Nós)

C) Extração dos dados

- “Raw” dataset utilizado durante a segunda parte da demonstração:
 - Importação dos Dados Brutos (Upload = *Landing Zone*)

Persons

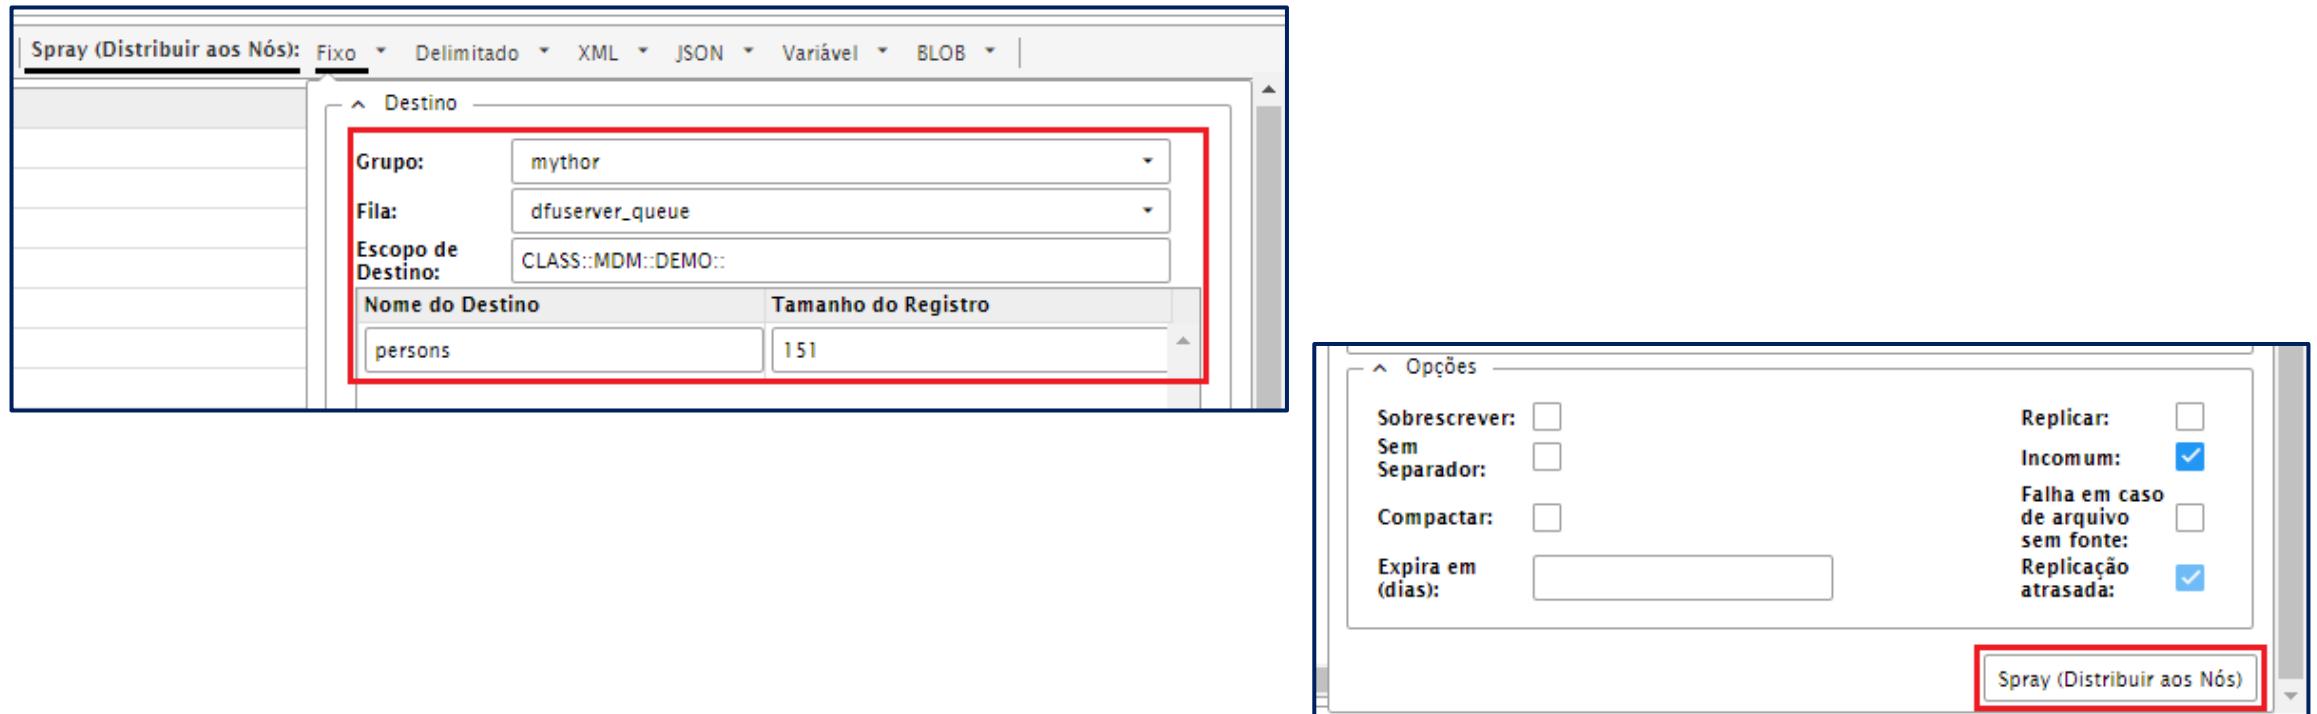
Fixo: 151

963.512
registros

Zona de Entrada de Arquivos						
Largura:	151	▼	EBCDIC:	<input type="checkbox"/>	+	
1	0000 AB**Cherianne	Khatchatourian	N	19990922.. M*	69 BOULDER RIDGE RD # 25A	HAWKINS
2	0097 BB**Muyesser	Raplee	X	20001111a.. F*	55 SWAMP RD	DISTRICT HEIGHT
3	012e CB**Roselin	Viceconte		19990325X.. F*19800113107 HILL TER		ENTERPRISE
4	01c5 DB**Inda	Provines		20000909.. U*	290 W MOUNT PLEASANT AVE	LAVACA
5	025c EB**Inderdeep	Laurence	D	20001228X.. M*	44 PROSPECT PL	GREENSBORO
6	02f3 FB**Chrystine	Mangiapane		19990827.. F*197803061806 1ST AVE APT 8F		ARVADA
7	038a GB**Adelene	Stock	R	20000827U.. M*	1117 FARM RD	DOVER
8	0421 HB**Mendy	Rufenblanchette		20000903.. M*	3 W 83RD ST APT 4C	WILLIAMSTON
9	04b8 IB**Lannie	Amerantes	I	20001219.. U*	200 W 20TH ST APT 909	CHARLESTON
10	054f JB**Tare	Gonyeau	T	199308070.. F*197508016 CANDLE CT		EL PASO
11	05e6 KB**Finney	Aristilde	P	19900621X.. M*19560920222 1ST AVE APT 2B		MACON
12	067d LB**Oreoluwa	Marthalier		19931006f.. F*19731201176 CLAREMONT GDNS		AUBURN
13	0714 MB**Surge	Abbottkrepp	D	20000308.. F*	22 LE PARC CT	TWINSBURG
14	07ab NB**Dave	Mcjury		20001129i.. U*	510 COOPER RD # 1	TACOMA
15	0842 OB**Ramsay	Ping		20001129i.. M*	404 AVENUE L	MESQUITE
16	08d9 PB**Lacides	Wisniveskydr	Q	20001227.. M*	23 JEFFERSON LN	ALTON BAY
17	0970 QB**Hazele	Scoggins	H	20001102.. M*	43 RENAISSANCE DR	COTATI
18	0a07 RB**Laini	Mandrake	B	20001205.. M*	5 SHEVCHENKO AVE	CROSS RIVER
19	0a9e SB**Setthaphon	Zeuli	N	20000922d.. M*196212011714 E WILLOW GROVE AVE		FORT WORTH
20	0b35 TB**Tomasa	Drabick	U	19830116.. F*19550901155 E 34TH ST # 20		LEES SUMMIT
21	0bcc UB**Ginabelle	Munkel	Q	20000914.. M*	833 SUMMER ST STE 3B	NEW ALEXANDRIA
22	0c63 VB**Ornah	Aschermann		200012079.. M*	36 UNION ST	CHARTLEY
23	0cfa WB**Moisey	Shupp	R	200012299.. M*	12 STEEPLECHASE LN	ATTALLA
24	0d91 XB**Jynevelyne	Hirschkind		19870618.. F*19630324404 SUMMIT AVE		PEPPERELL
25	0e28 YB**Norli	Pisciotta	V	19870320.. F*1933120123 SEVINOR RD # 0		FORT GEORGE G M
26	0ebf ZB**Toai	Ibric		20000706.. M*	17 TOLKIEN PSGE	MADISONVILLE
27	0f56 [B**Murshell	Bykov		20001209a.. F*	2142 MOUNTAIN VIEW AVE	PALM COAST

C) Extração dos dados

- **Spray para a distribuição do arquivo entre os ‘nós’ do Cluster:**
 - Spray do arquivo (Spray = *Logical Files*)



C) Extração dos dados

▪ Definição da Estrutura de Dados & Análise do Perfil (*Profiling*) dos dados

```
EXPORT modPersons := MODULE
EXPORT Layout := RECORD
    INTEGER4 RecID;
    STRING15 FirstName;
    STRING25 LastName;
    STRING15 MiddleName;
    STRING2 NameSuffix;
    STRING8 FileDate;
    UNSIGNED2 BureauCode;
    STRING1 MaritalStatus;
    STRING1 Gender;
    UNSIGNED1 DependentCount;
    STRING8 BirthDate;
    STRING42 StreetAddress;
    STRING20 City;
    STRING2 State;
    STRING5 ZipCode;
END;
EXPORT File := DATASET('~CLASS::MDM::DEMO::persons', Layout, THOR);
END;
```

##	recid	firstname	lastname	middlename	namesuffix	filedate	bureaucode	maritalstatus	gender	dependentcount	birthdate	streetaddress
1	1000001	Cherianne	Khatchatourian	N		19990922 24		M	4			69 BOULDER RIDGE RD #
2	1000002	Muyesser	Raplee	X		20001111 353		F	0			55 SWAMP RD
3	1000003	Roselin	Viceconte			19990325 344		F	4		19800113	107 HILL TER
4	1000004	Inda	Provines			20000909 13		U	3			290 W MOUNT PLEASANT P
5	1000005	Inderdeep	Laurence	D		20001228 344		M	3			44 PROSPECT PL
6	1000006	Chrystine	Mangiapane			19990827 315		F	0		19780306	1806 1ST AVE APT 8F
7	1000007	Adelene	Stock	R		20000827 252		M	0			1117 FARM RD
8	1000008	Mendy	Rufenblanchette			20000903 24		M	1			3 W 83RD ST APT 4C
9	1000009	Lannie	Amerantes	I		20001219 313		U	0			200 W 20TH ST APT 909
10	1000010	Tare	Gonyeau	T		19930807 48		F	0		19750801	6 CANDLE CT
11	1000011	Finney	Aristilde	P		19900621 344		M	2		19560920	222 1ST AVE APT 2B
12	1000012	Oreoluwa	Marthalier			19931006 358		F	5		19731201	176 CLAREMONT GDNS
13	1000013	Surge	Abbottkrepp	D		20000308 13		F	4			22 LE PARC CT
14	1000014	Dave	Mcjury			20001129 238		U	1			510 COOPER RD # 1

C) Extração dos dados

- Limpeza, padronização e consolidação de registros

##	recid	id	firstname	lastname	middlename	namesuffix	filedate	bureaucode	gender	birthdate	streetaddress	city	state	zipcode
1	1	1000001	CHERIANNE	KHATCHATOURIAN	N		19990922	24	M	0	69 BOULDER RIDGE RD # 25A	HAWKINS	WI	54530
2	2	1000002	MUYESSER	RAPLEE	X		20001111	353	F	0	55 SWAMP RD	DISTRICT HEIGHT	MD	20747
3	3	1000003	ROSELIN	VICECONTE			19990325	344	F	19800113	107 HILL TER	ENTERPRISE	OR	97828
4	4	1000004	INDA	PROVINES			20000909	13	U	0	290 W MOUNT PLEASANT AVE	LAVACA	AR	72941
5	5	1000005	INDERDEEP	LAURENCE	D		20001228	344	M	0	44 PROSPECT PL	GREENSBORO	FL	32330
6	6	1000006	CHRYSTINE	MANGIAPANE			19990827	315	F	19780306	1806 1ST AVE APT 8F	ARVADA	CO	80007
7	7	1000007	ADELENE	STOCK	R		20000827	252	M	0	1117 FARM RD	DOVER	DE	19901
8	8	1000008	MENDY	RUFENBLANCHETTE			20000903	24	M	0	3 W 83RD ST APT 4C	WILLIAMSTON	SC	29697
9	9	1000009	LANNIE	AMERANTES	I		20001219	313	U	0	200 W 20TH ST APT 909	CHARLESTON	WV	25312
10	10	1000010	TARE	GONYEAU	T		19930807	48	F	19750801	6 CANDLE CT	EL PASO	TX	79924
11	11	1000011	FINNEY	ARISTILDE	P		19900621	344	M	19560920	222 1ST AVE APT 2B	MACON	GA	31220
12	12	1000012	OREOLUWA	MARTHALER			19931006	358	F	19731201	176 CLAREMONT GDNS	AUBURN	ME	4210
13	13	1000013	SURGE	ABBOTTKREPP	D		20000308	13	F	0	22 LE PARC CT	TWINSBURG	OH	44087

RoadMap 02 - Sequência dos códigos ECL:

ETL - ECL codes (*Target* = Thor):

1. modPersons.ecl
2. BWR_Persons_CSV (submit = opcional para CSV testes)
3. modPersons_CSV.ecl (opcional para CSV testes)
4. BWR_BrowseData02.ecl (submit)
5. BWR_DP_Persons.ecl (submit = opcional para CSV testes)
6. Demo06.ecl (submit)
7. Demo07.ecl (submit)
8. UID_Persons.ecl
9. STD_Persons.ecl
10. BWR_BrowseData03.ecl (submit)

Minicurso: Agenda

✓ LexisNexis Risk Solutions: A Empresa

- ✓ Quem somos nós?
- ✓ A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

➤ ***HPCC Systems: Visão Geral***

- ✓ Apresentação de conceitos;
- ✓ Aplicação de conhecimentos;
- Desenvolvimento de um serviço de consulta;
- Utilização de algoritmos de Aprendizado de Máquina.

➤ **Atividades de treinamento**

- Cursos *online*;
- Projetos de pesquisa;
- Oportunidades profissionais.

➤ **Considerações Finais**

HPCC Systems: Visão geral

- Desenvolvimento de um serviço de consulta: Dados Pessoais

The screenshot shows the HPCC Systems Roxie interface. At the top, it displays the service name "fetch_persons_mdm" and a "Dynamic Form" button. Below this, a section titled "FETCH_PERSONS_MDMREQUEST" contains three input fields: "firstname_value", "lastname_value", and "state_value". At the bottom, there are four buttons: "Output Tables" (selected), "FORM POST", "Submit", and "Clear All".

RoadMap 03 - Sequência dos códigos ECL:

❑ Consulta - ECL codes (*Target* = Thor | Código 3, compilar *Target* = Roxie):

1. IDX_Persons.ecl
2. BWR_BuildIndexes.ecl (submit)
3. Fetch_Persons.ecl (compile em Roxie)
4. BWR_TestQueries.ecl (submit)

Minicurso: Agenda

✓ LexisNexis Risk Solutions: A Empresa

- ✓ Quem somos nós?
- ✓ A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

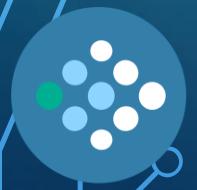
➤ **HPCC Systems: Visão Geral**

- ✓ Apresentação de conceitos;
- ✓ Aplicação de conhecimentos;
- ✓ Desenvolvimento de um serviço de consulta;
- Utilização de algoritmos de Aprendizado de Máquina.

➤ **Atividades de treinamento**

- Cursos *online*;
- Projetos de pesquisa;
- Oportunidades profissionais.

➤ **Considerações Finais**



HPCC[™]
SYSTEMS



*Machine
Learning*

HPCC Systems: Visão geral

- Utilização de algoritmos de ML – Serviço de consulta (ESP): Preço de Imóveis

The image displays two identical-looking web forms side-by-side, both titled "fn_myriadgetpricereg_web" and "Dynamic Form". The forms are titled "FN_MYRIADGETPRICEREG_WEBREQUEST" and contain ten input fields for real estate data: "_state_01", "_state_02", "_state_03", "assess_val", "bedrooms", "full_baths", "half_baths", "land_sq_ft", "living_sq_ft", "year_acq", "year_built", and "zip". Below the input fields are three checkboxes: "Capture Log Info.", "Trace Level: [input field]", and "No Timeout". At the bottom are four buttons: "Call Query", "Output Tables", "FORM POST", "Submit", and "Clear All".

HPCC Systems: Visão geral

▪ Utilização de algoritmos de ML – Serviço de consulta (Web): Preço de Imóveis

ERAD-SE 2025

\$ Preço do Imóvel por Estado ⓘ

Estados (EUA):

Valor avaliado:

Nº de quartos:

Nº de banheiros:

Nº de lavabos:

Área construída (ft²):

Área interna (ft²):

Ano de aquisição [AAAA]:

Ano de construção [AAAA]:

CEP:

Consulta **Reset**

Mauro Marques

Copyright © 2025
LexisNexis Risk Solutions

Estados dos EUA disponíveis na base de dados:

AK	Alasca	MT	Montana
AL	Alabama	NC	Carolina do Norte
AR	Arkansas	ND	Dakota do Norte
AZ	Anzona	NE	Nebraska
CA	Califórnia	NH	Nova Hampshire
CO	Colorado	NJ	Nova Jérsei
CT	Connecticut	NM	Nova México
DE	Delaware	NV	Nevada
FL	Florida	NY	Nova Iorque
GA	Geórgia	OH	Ohio
HI	Havaí	OK	Oklahoma
IA	Iowa	OR	Oregon
ID	Idaho	PA	Pensilvânia
IL	Illinois	RI	Rhode Island
IN	Indiana	SC	Carolina do Sul
KS	Kansas	SD	Dakota do Sul
KY	Kentucky	TN	Tennessee
LA	Louisiana	TX	Texas
MA	Massachusetts	UT	Utah
MD	Maryland	VT	Vermont
ME	Maine	VA	Virginia
MI	Michigan	WA	Washington
MN	Minnesota	WI	Wisconsin
MO	Missouri	WV	Virgínia Ocidental
MS	Mississippi	WY	Wyoming

Treinamento na plataforma HPCC Systems

Preço do Imóvel por Estado ⓘ

Estados (EUA):

Valor avaliado:

Nº de quartos:

Nº de banheiros:

Nº de lavabos:

Área construída (ft²):

Área interna (ft²):

Ano de aquisição [AAAA]:

Ano de construção [AAAA]:

CEP:

Consulta **Reset**

Mauro Marques

Aprendizado de Máquina

- “Raw” dataset utilizado durante a terceira parte da demonstração:
 - Importação dos Dados Brutos (Upload = *Landing Zone*)

Property.csv

Delimitado

1.662.959
registros

##	propertyid	house_number	house_number_suffix	predir	street	streettype	postdir	apt	city	state	zip	total_value	assessed_value
1	828195	144			MCKIERNAN	DR			WALNUT CREEK	CA	94597	62614	62614
2	1144455	281			CENTER	ST			BALTIMORE	MD	21136	105500	10550
3	1494347	483			NEWTON	RD			FLAGSTAFF	AZ	86011	2220	2220
4	1910847	802			HATCHERY	CT			WOODLAND	WA	98674	356000	356000
5	4267562	5007		E	ROY ROGERS	RD			TROY	MI	48085	327253	327253
6	4888602	7607			PEBBLESTONE	DR		000009	KERNVILLE	CA	93238	732179	732179
7	54135	4			WAINWRIGHT	DR			NORTH FORT MYERS	FL	33917	159724	87848
8	762012	125			SHIPIARD	DR		000150	MELBOURNE VILLAGE	FL	32904	96300	96300
9	2331721	1190			LITTLEOAK	DR			HOUSTON	TX	77011	238854	217810
10	3276109	2506			MEADOW	DR			LA QUINTA	CA	92253	30977	30660

Aprendizado de Máquina

■ Visão geral – Conceituação

A característica principal do *Machine Learning* é a capacidade de inferir sobre relacionamentos e, visa prever uma resposta razoável quando apresentado com dados nunca antes vistos.

O "aprendizado" do *Machine Learning (ML)* tem várias categorias:

- **Supervisionado** - O tipo mais comum de *ML*. Esse método envolve o treinamento do sistema em que os *recordset*, juntamente com o padrão de saída de destino, são fornecidos ao sistema para executar uma tarefa.
- **Não Supervisionado** - Este método não envolve a saída de destino, o que significa que nenhum treinamento é fornecido ao sistema. O sistema precisa aprender por meio da determinação e adaptação de acordo com as características estruturais nos padrões de entrada.
- **Deep Learning** - Move-se para a área dos métodos *ML* de Redes Neurais (*Neural Networks - NNs*). O *Deep Learning* implica várias camadas maiores que '2' e, também, implica em técnicas utilizadas com dados complexos, como análise de vídeo ou áudio.

Aprendizado de Máquina

■ Aprendizado Supervisionado

A premissa básica do *ML Supervisionado* é que, dado um conjunto de “amostras de dados” (registros) e um conjunto de “valores-alvo” em campo e formato de registro, que ele aprenda como prever “valores-alvo para novas amostras”.

Amostras de dados: conhecidas como variáveis “Independentes”, porque são as informações fornecidas e não dependem de nenhum outro dado. Variáveis Independentes também são conhecidas como ‘Características’ (*Features*) dos dados.

Valores-alvo: conhecidos como variáveis “Dependentes”, porque eles são de alguma forma dependentes das amostras de dados.

As variáveis ‘Independentes’ e ‘Dependentes’ juntas são conhecidas como “conjunto de treinamento”.

Dois tipos básicos de Modelos de Análise em Aprendizado Supervisionado:

Quantitativo - conhecido como “Regressão” - Implica um valor numérico;

Qualitativo - conhecido como “Classificação” - Implica uma categoria ou, às vezes, um resultado binário.

Aprendizado de Máquina

■ *Machine Learning Bundles da plataforma HPCC Systems*

Os *bundles* de produção (excluindo os *bundles* de suporte **ML_Core** e **PBblas**) fornecem uma interface principal muito semelhante para o *Machine Learning*. No entanto, cada algoritmo tem suas próprias peculiaridades (suposições e restrições) que devem ser levadas em consideração.

É importante ler a documentação que acompanha cada *bundle* para usá-lo efetivamente.

➤ Link definitivo para todos os *bundles* de produção, sua documentação e tutoriais, quando aplicável:

[<https://hpccsystems.com/download/free-modules/machine-learning-library>].

Aprendizado de Máquina

■ *Machine Learning Bundles*

a. *Bundles* Principais:

- ***ML_Core - Machine Learning Core***

Fornece as principais definições de dados para *ML*. É um pré-requisito para todos os outros *bundles* configuráveis de produção.

➤ Mais informações: [https://github.com/hpcc-systems/ML_Core].

- ***PBblas - Parallel Block Basic Linear Algebra Subsystem***

Fornece operações de matriz escalonáveis e distribuídas usadas por vários dos outros *bundles* configuráveis. Também pode ser usado diretamente sempre que as operações da matriz estiverem em ordem. Essa é uma dependência para vários dos outros *bundles* configuráveis.

➤ Mais informações: [<https://github.com/hpcc-systems/PBblas>].

Aprendizado de Máquina

■ *Machine Learning Bundles*

b. *Bundles de Aprendizado Supervisionado:*

- ***LearningTrees*** (baseado no algoritmo clássico “***ML RandomForest***”)

Classificação e Regressão baseadas em Árvores de Decisão. Um dos melhores métodos de *ML* "prontos para uso", pois faz poucas suposições sobre a natureza dos dados e é resistente ao “*overfitting*” (*). Capaz de lidar com um grande número de variáveis independentes. Cria uma “floresta” de diversas Árvores de Decisão e calcula a média das respostas das diferentes Árvores.

➤ Mais informações: [<https://github.com/hpcc-systems/LearningTrees>].

(*) **Superajuste (*overfitting*)**: Muitos algoritmos tendem a superestimar o conjunto de treinamento. Isso significa que ele está reduzindo o erro de previsão ajustando-se ao ruído que ocorre nesse conjunto de dados. Um modelo de excesso de ajuste tratará esse ruído como sinal e usará o que aprendeu para prever os próximos dados apresentados. Infelizmente, esse próximo conjunto de dados estará sujeito a um conjunto de ruído completamente diferente, o que não fornecerá bons resultados.

Aprendizado de Máquina

- **ML Supervisionado: Árvores de Decisão (*Learning Trees - Random Forests*)**

As Árvores de Decisão têm sido utilizadas, pelo menos, desde a década de 1930 como uma forma de estruturar o conhecimento usando um conjunto de regras em cascata. Elas são conceitualmente simples e razoavelmente fáceis de entender e interpretar.

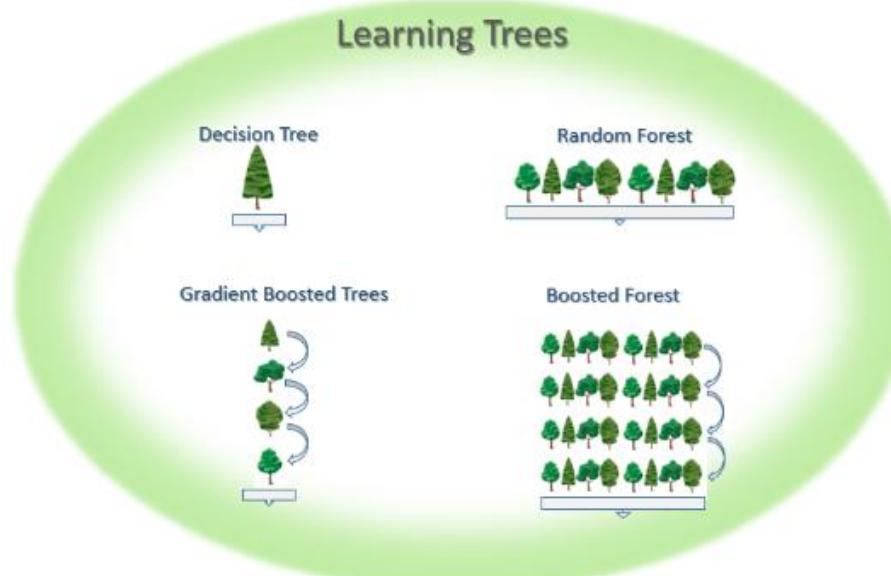
Random Forest são facilmente “paralelizáveis”, sendo, portanto, um algoritmo ideal para uso em *clusters* do **HPCC Systems**.

O *LearningTrees bundle* fornece uma implementação eficiente e escalável dos métodos *Learning Trees*. Atualmente, fornece algoritmos de "Decision Trees", "Random Forest", "Gradient Boosted Trees" e "Boosted Forest".

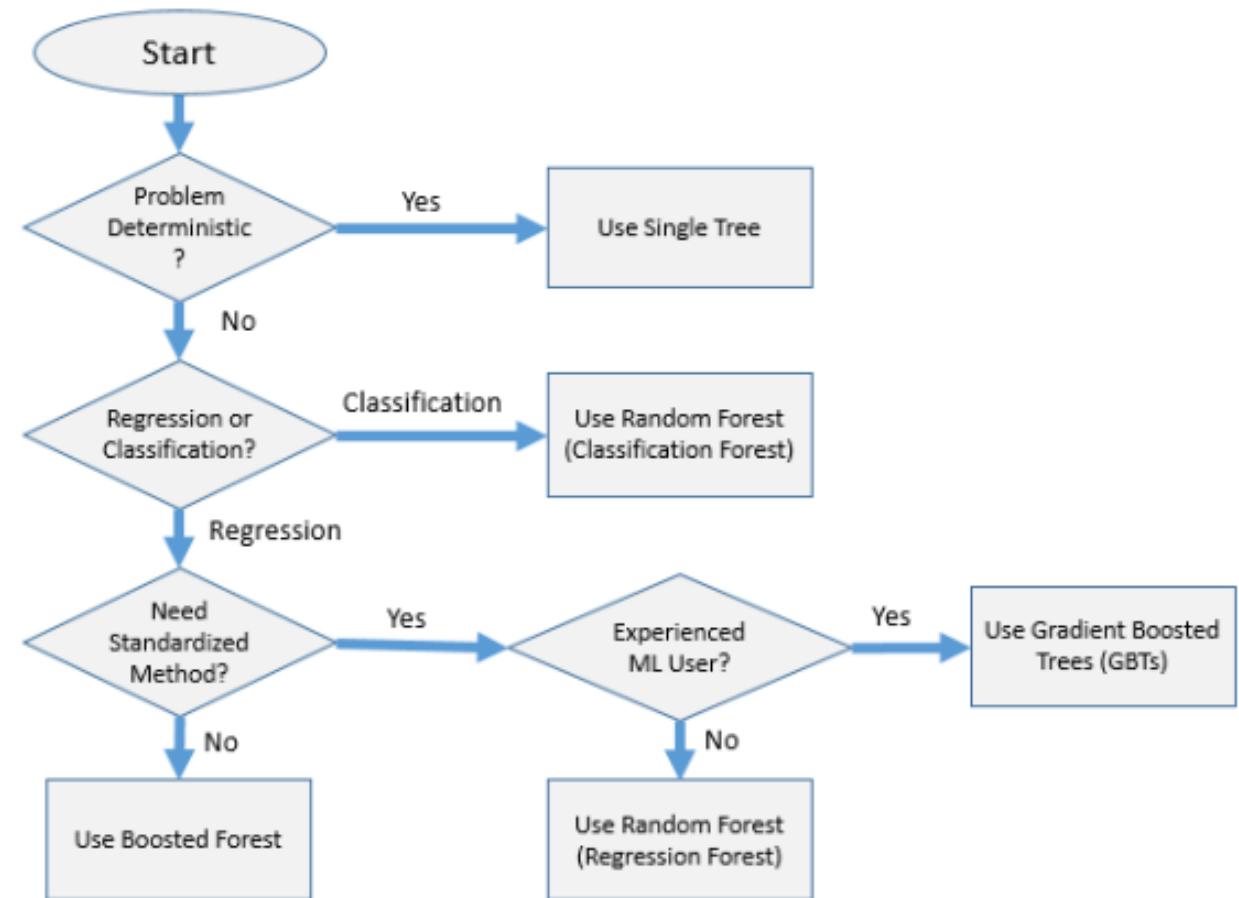
Diante dos diversos algoritmos disponíveis, qual algoritmo se deve escolher?

Aprendizado de Máquina

■ ML Supervisionado: Árvores de Decisão (*Learning Trees - Random Forests*)

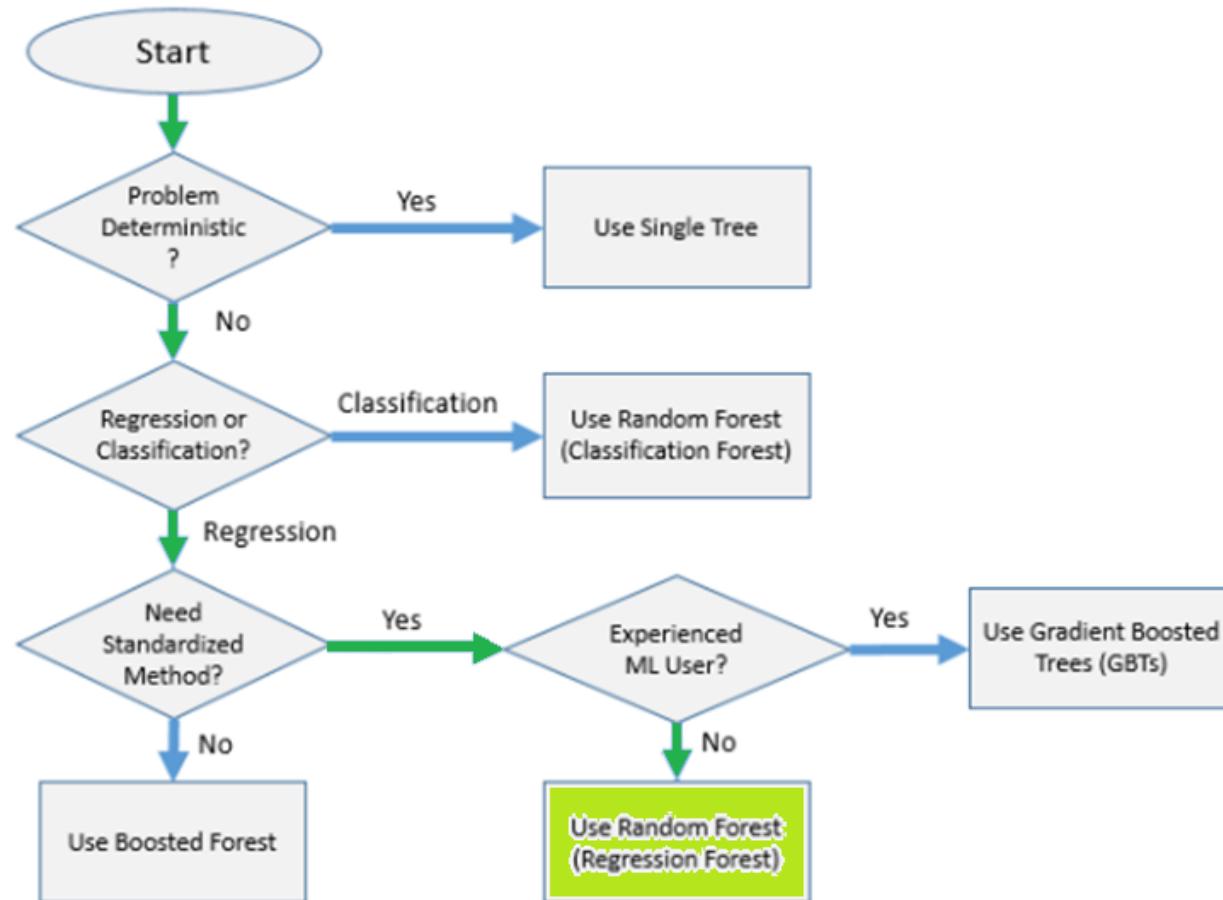


Esse fluxograma pode ser usado para auxiliar nessa escolha



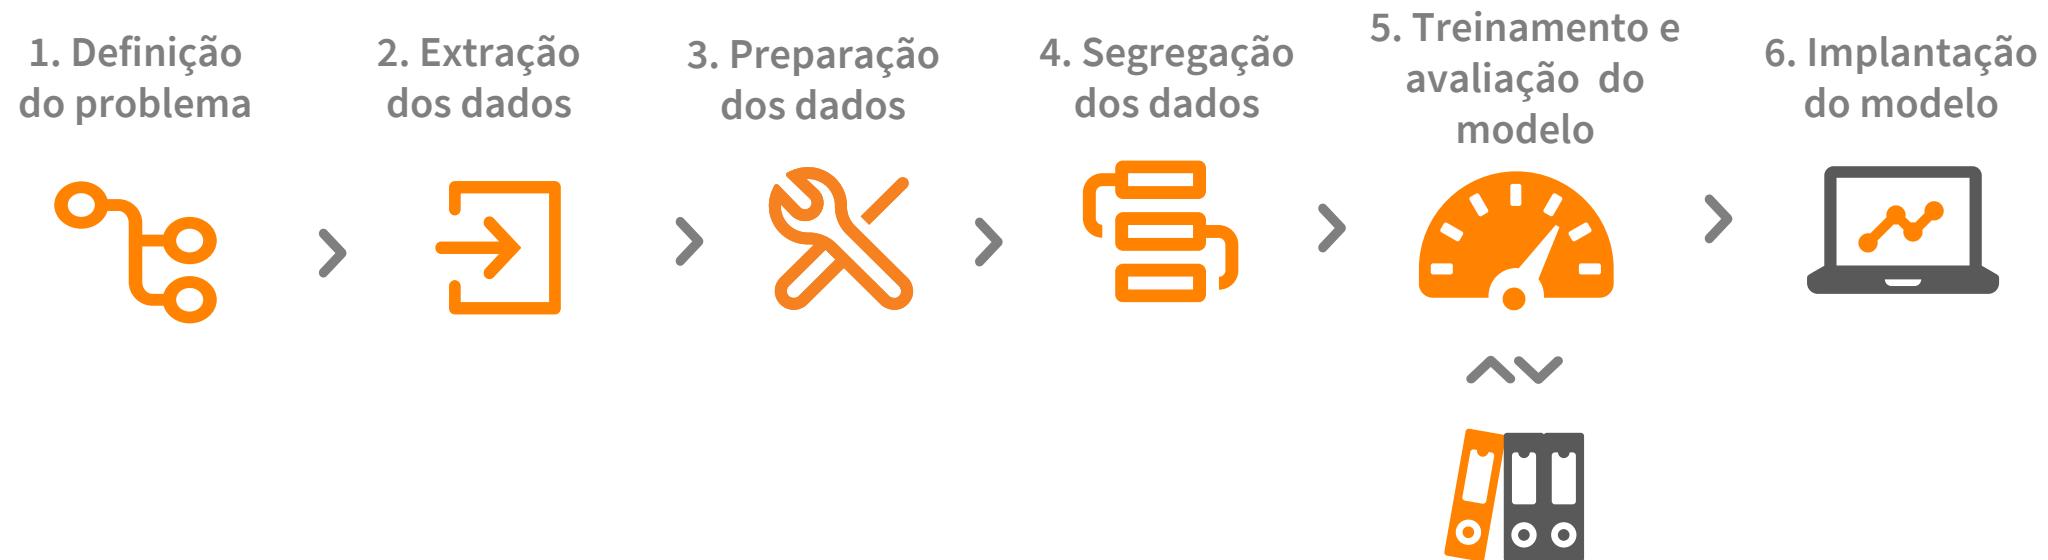
Aprendizado de Máquina

- **ML Supervisionado: Árvores de Decisão (*Learning Trees - Random Forests*)**



Aprendizado de Máquina

▪ Fluxo de Aprendizado de Máquina Supervisionado



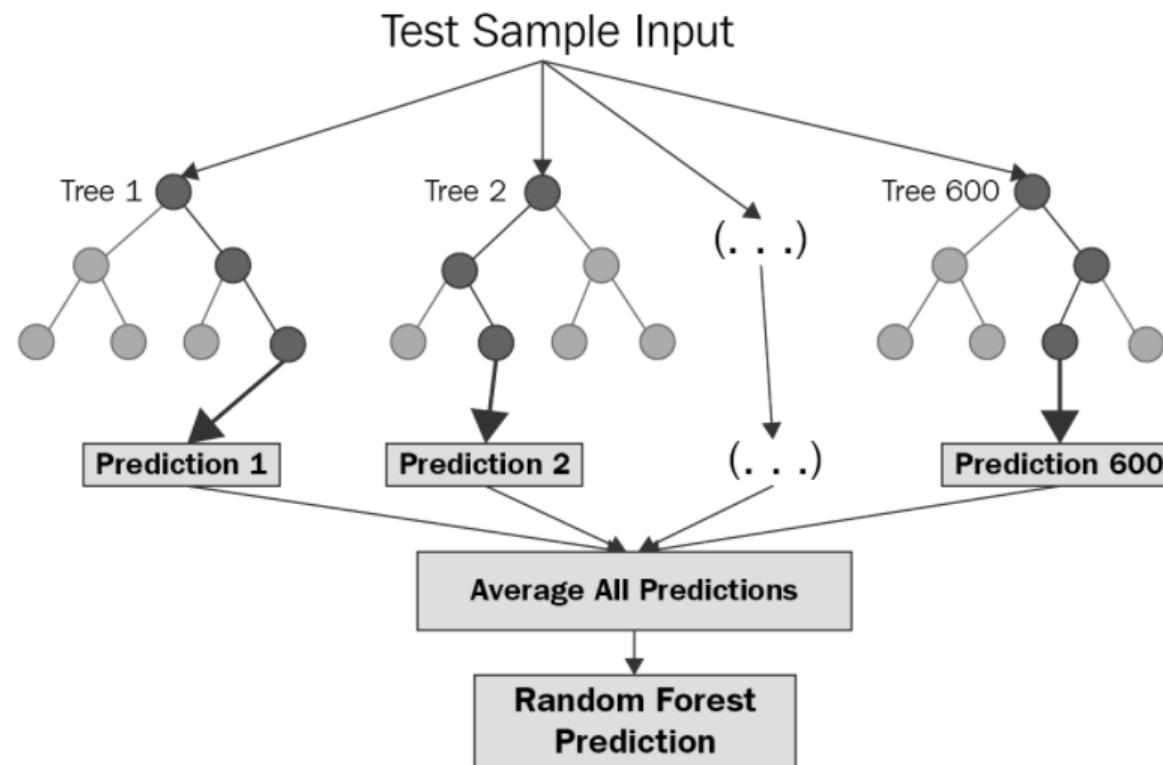
1. Definição do problema

- “Dado um conjunto de atributos de uma propriedade (localização, m², ano de construção/aquisição, nº cômodos, etc), como predizer o seu valor real de venda?”

propertyid	house_number	house_nu	predir	street	streett	postdir	apt	city	state	zip	total_value	assessed_value	year_acquired	land_square_foot	living_square_feet	bedrooms	full_baths
828195	144			MCKIERNAN	DR			WALNUT CREEK	CA	94597	62614	52614	2006	20418	2485	3	2
1144455	281			CENTER	ST			BALTIMORE	MD	21136	105500	10550	2007	4807	1368	0	0
1494347	483			NEWTON	RD			FLAGSTAFF	AZ	86011	2220	2220	0	5654	1011	3	1
1910847	802			HATCHERY	CT			WOODLAND	WA	98674	356000	356000	0	6094	0	2	1
4267562	5007		E	ROY ROGERS	RD			TROY	MI	48085	327253	327253	2007	3484	0	3	0
4888602	7607			PEBBLESTONE	DR		000009	KERNVILLE	CA	93238	732179	732179	2010	19597	6132	6	6
48725	4			LONG	AVE			SUNRISE	FL	33323	271000	271000	2008	6880	2392	4	2
83528	6			TRILLUM	LN			WAYLAND	MA	02193	79889	79889	2007	7657	1657	4	1
94604	7			PARMENTER	AVE			PLYMOUTH	MN	55441	23800	23800	2005	19994	1754	3	2
220326	17			TIMBER	RD			LOS ANGELES	CA	90063	89000	89000	2008	7840	954	3	1
994609	212			FREYER	DR	NE		PHILOMONT	VA	20131	59800	59800	2009	11199	1241	3	0
1836173	724			EASTER	ST			ALLENTOWN	PA	18102	191600	191600	0	9100	2534	4	2
2910797	1903			SADDLE BROOK	DR			CLIO	CA	96106	61610	51610	2007	0	0	0	0
3083959	2158			RIVERSIDE	DR			UPPER MOREL...	PA	19006	90300	0	0	0	1235	3	2
3952189	4040			GRAND VIEW	BLVD		000054	RIO LINDA	CA	95673	0	0	2007	2700720	0	0	0
4186238	4726			LAS PALMAS	CT			WAELDER	TX	78959	18816	18816	2009	2159	1320	0	0
4597143	6213			WILSON	RD			ZOLFO SPRINGS	FL	33890	72600	0	0	8496	0	3	1
4624905	6321			STONEWALL	LN			PATERSON	NJ	07514	139880	139880	2008	10454	1391	4	2
92326	7			KNOLLCREST	DR			NARANJA	FL	33032	76214	76214	2008	4800	930	2	0
1792852	704			ERIN	DR			TRABUCO	CA	92678	28010	28010	2007	5200	0	3	1
1843977	728		S	ARLINGTON HE...	RD			BLOOMING GRO...	TX	76626	130400	130400	2007	36154	1629	3	1
4214872	4821			MURKIE OAK	DR		000025	SAM BERNARDT	CA	92376	22250	0	2007	93654	0	0	0

1. Definição do problema (cont.)

- Árvores de Decisão – *Learning Trees*



2. Extração dos dados

■ Importação e análise dos dados

##	personid	propertyid	house_number	house_number_suffix	predir	street	streettype	postdir	apt	city	state	zip	total_value
1	187522928604396	828195	144			MCKIERNAN	DR			WALNUT CREEK	CA	94597	62614
2	187522928604396	1144455	281			CENTER	ST			BALTIMORE	MD	21136	105500
3	187522928604396	1494347	483			NEWTON	RD			FLAGSTAFF	AZ	86011	2220
4	187522928604396	1910847	802			HATCHERY	CT			WOODLAND	WA	98674	356000
5	187522928604396	4267562	5007		E	ROY ROGERS	RD			TROY	MI	48085	327253
6	187522928604396	4888602	7607			PEBBLESTONE	DR		000009	KERNVILLE	CA	93238	732179
7	1258313199446079	48725	4			LONG	AVE			SUNRISE	FL	33323	271000
8	1258313199446079	83528	6			TRILLUM	LN			WAYLAND	MA	02193	79889
9	1258313199446079	94604	7			PARMENTER	AVE			PLYMOUTH	MN	55441	23800
10	1258313199446079	220326	17			TIMBER	RD			LOS ANGELES	CA	90063	89000
11	1258313199446079	994609	212			FREYER	DR	NE		PHILOMONT	VA	20131	59800
12	1258313199446079	1836173	724			EASTER	ST			ALLENTOWN	PA	18102	191600
13	1258313199446079	2910797	1903			SADDLE BROOK	DR			CLIO	CA	96106	61610
14	1258313199446079	3083959	2158			RIVERSIDE	DR			UPPER MORELAND	PA	19006	90300
15	1258313199446079	3952189	4040			GRAND VIEW	BLVD		000054	RIO LINDA	CA	95673	0

3. Preparação dos dados

- Limpeza, padronização e consolidação de registros

##	propertyid	zip	assessed_value	year_acquired	land_square_footage	living_square_feet	bedrooms	full_baths	half_baths	year_built	total_value
1	79784	33424	76440	2015	4299	1255	3	2	0	2010	76440
2	3924129	20601	95900	2013	11224	1468	3	2	1	2007	95900
3	413843	8803	76000	2015	57000	1858	3	2	0	1970	76000
4	608224	98370	39340	2012	7405	1066	3	1	1	1967	39340
5	942963	72032	278400	2008	9600	2459	3	2	0	1963	278400
6	2237271	79935	143600	2011	8430	1008	2	1	1	1961	143600
7	4443742	84065	166934	2013	9317	1700	4	2	0	1991	166934
8	3834707	66227	348350	2012	15300	2663	4	2	1	2002	348350
9	3592739	19606	54000	2015	15060	2292	4	2	1	1980	90000
10	2916349	34639	119050	2015	6947	1709	3	2	0	2009	140950

4. Segregação dos dados

- Seleção aleatória de amostras de treinamento e validação com a distinção de variáveis independentes e dependentes

##	wi	id	number	value
1	1	79784	1	33424.0
2	1	79784	2	76440.0
3	1	79784	3	2015.0
4	1	79784	4	4299.0
5	1	79784	5	1255.0
6	1	79784	6	3.0
7	1	79784	7	2.0
8	1	79784	8	0.0
9	1	79784	9	2010.0
10	1	3924129	1	20601.0

##	wi	id	number	value
1	1	79784	1	76440.0
2	1	3924129	1	95900.0
3	1	413843	1	76000.0
4	1	608224	1	39340.0
5	1	942963	1	278400.0
6	1	2237271	1	143600.0
7	1	4443742	1	166934.0
8	1	3834707	1	348350.0
9	1	3592739	1	90000.0
10	1	2916349	1	140950.0

##	wi	id	number	value
1	22	2292044	1	6751.0
2	22	2292044	2	75837.0
3	22	2292044	3	2013.0
4	22	2292044	4	3484.0
5	22	2292044	5	763.0
6	22	2292044	6	1.0
7	22	2292044	7	1.0
8	22	2292044	8	1.0
9	22	2292044	9	2002.0
10	16	3675939	1	12546.0

##	wi	id	number	value
1	22	2292044	1	75837.0
2	16	3675939	1	131500.0
3	3	4346206	1	78954.0
4	3	4168683	1	65000.0
5	18	2956615	1	168821.0
6	41	2622288	1	65568.0
7	18	1196844	1	36100.0
8	43	114945	1	19796.0
9	6	961534	1	156893.0
10	41	882691	1	71786.0

Interface Myriad

5. Treinamento e avaliação do modelo

- Obtenção de modelo a partir da amostra de treinamento e validação na amostra de teste

##	wi	id	number	value
1	1	3634	1	59055.31318837311
2	1	5840	1	126151.3283316611
3	1	12721	1	150876.4676173128
4	1	47045	1	233897.4086392291
5	1	91757	1	111950.2604939628
6	1	117238	1	81157.13156934927
7	1	149746	1	75868.58107175257
8	1	239046	1	39961.17077444747
9	1	246517	1	128203.9088547347
10	1	252615	1	69009.47259550788

##	wi	regressor	r2	mse	rmse
1	48	1	1.0	7899654400.0	88880.0
2	40	1	0.9311376324090863	86100656.52500002	9279.043944555928
3	6	1	0.8407434005563046	1188713430.574167	34477.72368608703
4	53	1	0.8065354715574288	2619422585.198289	51180.29489166987
5	37	1	0.8051321121617373	3681390045.728787	60674.45958332705
6	41	1	0.8033767773856457	2630432563.605217	51287.74282033883
7	32	1	0.8003100933540183	1700812118.14	41240.90345930846
8	22	1	0.798261028979762	953955898.739406	30886.17649919468
9	34	1	0.7728380339814155	522134100.9433332	22850.25384855348
10	17	1	0.7696693188373955	2411024752.625271	49102.18684157836

##	wi	regressor	r2	mse	rmse
1	1	1	0.7304899830671003	7982069594.129144	89342.4288573416

Interface Myriad:
Ordernação pela Acurácia

6. Implantação do modelo

■ Carregamento de dados e disponibilização de serviço de consulta - *Myriad*

roxie
fn_myriadgetpricereg ◀ ▶ ↻ ↺ Dynamic Form ▼

FN_MYRIADGETPRICEREGREQUEST ✓

state:	CA
assess_val:	118720
bedrooms:	3
full_baths:	2
half_baths:	1
land_sq_ft:	14774
living_sq_ft:	1437
year_acq:	2011
year_built:	1968
zip:	95451

Capture Log Info. Trace Level: No Timeout

Call Query ▼ Output Tables ▼ FORM POST ▼ Submit Clear All

roxie
fn_myriadgetpricereg_web ◀ ▶ ↻ ↺ Dynamic Form ▼

FN_MYRIADGETPRICEREG_WEBREQUEST ✓

_state_01:	CA
_state_02:	NY
_state_03:	FL
assess_val:	118720
bedrooms:	3
full_baths:	2
half_baths:	1
land_sq_ft:	14774
living_sq_ft:	1437
year_acq:	2011
year_built:	1968
zip:	95451

Capture Log Info. Trace Level: No Timeout

Call Query ▼ Output Tables ▼ FORM POST ▼ Submit Clear All

Interface Myriad

- **ML Supervisionado: Árvores de Decisão (*Learning Trees* com Interface Myriad)**

Todos os *bundles* de *ML* de produção nativos na plataforma *HPCC Systems* suportam o que é chamado de “Interface Myriad”, que é uma maneira de executar muitas ações semelhantes em diferentes conjuntos de dados, com uma única invocação da interface. Por exemplo, pode-se querer criar um modelo separado para cada grande área metropolitana (cidade/estado) e, então, usar esse conjunto de modelos para prever dados para cada área usando o seu próprio modelo exclusivo.

Executar as atividades ao mesmo tempo permite aproveitar mais completamente o paralelismo do *cluster* da plataforma *HPCC Systems*, realizando todas as atividades em uma única invocação. Compare isso com a execução serial de cada atividade. Se cada atividade não puder usar o conjunto completo de nós da plataforma, porque é de tamanho moderado, ou o algoritmo específico não pode utilizar todos os nós de uma vez, muitos dos nós ficarão ociosos para cada atividade.

Interface Myriad

- **ML Supervisionado: Árvores de Decisão (*Learning Trees* com Interface Myriad)**

Executar as atividades uma de cada vez, portanto, permite que muitos nós sejam subutilizados durante toda a operação. Executar as atividades em paralelo, com a interface *Myriad*, possibilita que as atividades sejam balanceadas em todos os nós do *cluster*, maximizando assim o desempenho (ou seja, minimizando o tempo de execução).

Além disso, muitos dos algoritmos de *ML* exigem várias etapas sequenciais para concluir uma atividade. Cada etapa requer sincronização entre os nós do *cluster*. Quanto mais sincronizações forem necessárias, menos otimizado será o processamento paralelo dentro do *cluster*. Executar várias atividades em paralelo não aumenta o número de sincronizações em relação a uma única atividade, ainda que cada sincronização se torne maior (ou seja, mais dados).

Interface Myriad

■ **ML Supervisionado: Árvores de Decisão (*Learning Trees* com Interface Myriad)**

Embora sincronizações maiores afetem o desempenho, o impacto é pequeno em comparação ao aumento do número de etapas de sincronização. Isso ocorre devido à latência (atrasos) na comunicação de rede. Ao esperar por respostas de um nó para outro, nenhum trabalho pode ser realizado. Requisições maiores não criam atrasos tão improdutivos porque não há espera, exceto pelo tempo real da transferência de dados na rede.

Com a interface *Myriad*, pode-se invocar um único treinamento (ou seja, **GetModel(...)**) que retorne “n” modelos diferentes compactados em um só. Então, com uma única invocação de **Predict(...)**, pode-se fazer previsões sobre dados de todas as “n” áreas metropolitanas, cada uma em relação ao modelo aprendido apropriado para essa área. Pode-se então avaliar a precisão dos “n” modelos com uma única chamada para **Accuracy(...)**. Isso é conveniente do ponto de vista da programação, mas, mais importante ainda é poder fazer o melhor uso dos recursos de um *cluster* da plataforma *HPCC Systems*.

Interface Myriad

■ **ML Supervisionado: Árvores de Decisão (*Learning Trees* com Interface Myriad)**

A estratégia da interface *Myriad* está incorporada nas principais estruturas de registro usadas pelo *ML*. Lembrando que, o *ML* utiliza vários tipos principais de registro em suas interfaces:

- *NumericField* é usado para fornecer dados de valor real em forma de matriz;
- *DiscreteField* é usado para transmitir dados discretos (de valor inteiro); e
- *Layout_Model* é usado para codificar o Modelo que armazena tudo o que é aprendido sobre os dados.

Cada um desses layouts tem um campo conhecido como *work-item-id* (“wi”).

É esse *id* que fornece isolamento das várias atividades independentes na interface.

Interface Myriad

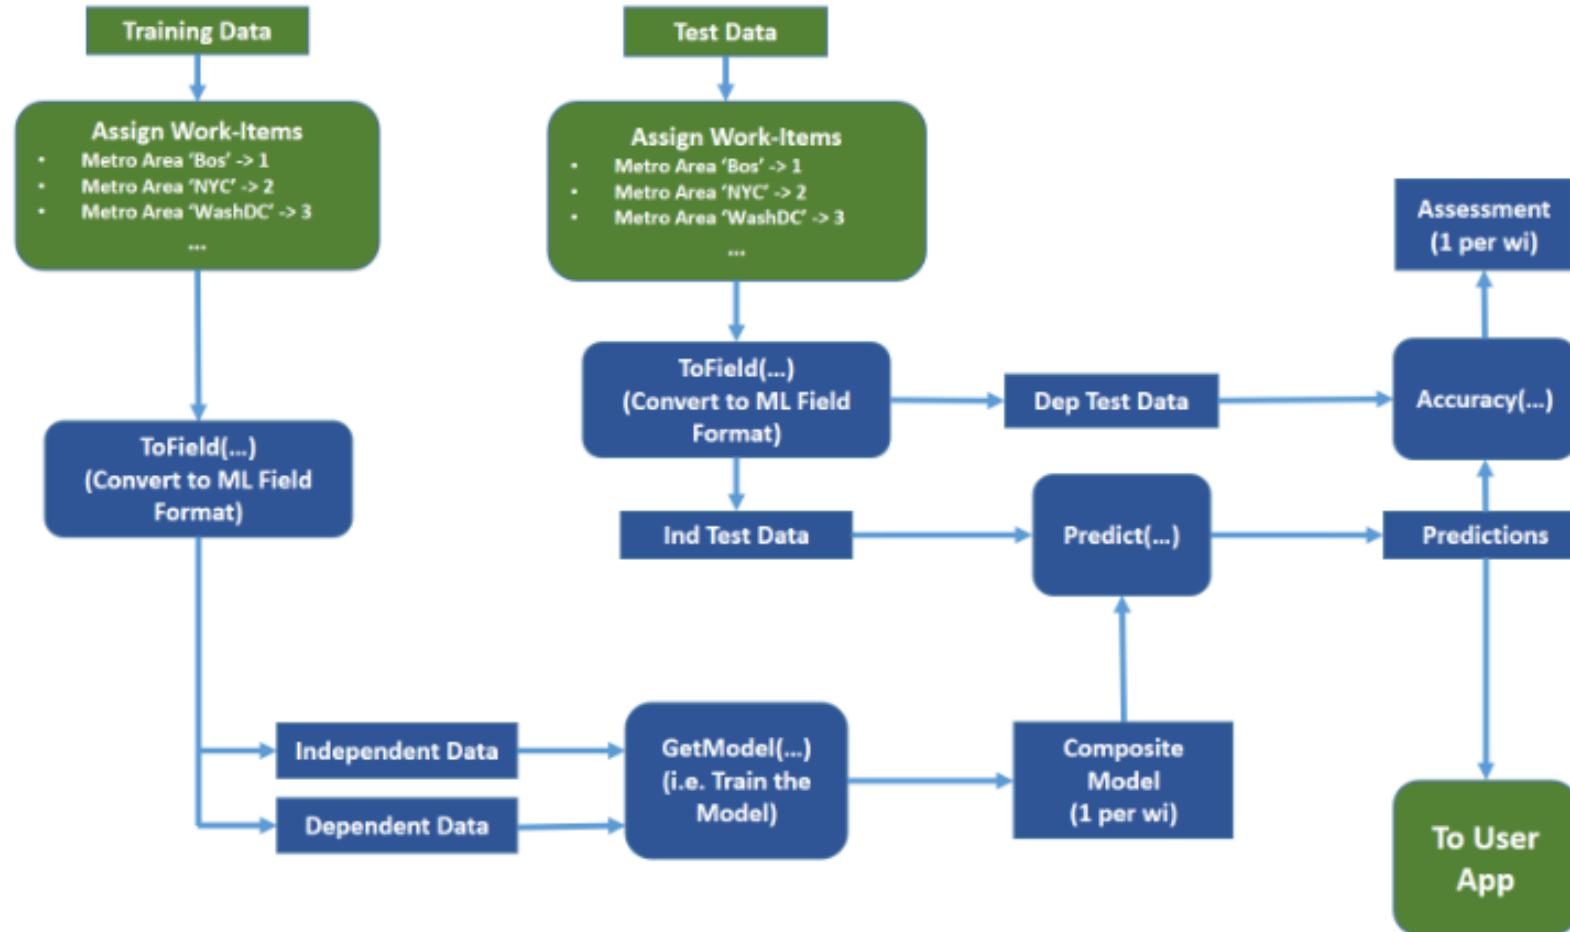
- **ML Supervisionado: Árvores de Decisão (*Learning Trees* com Interface Myriad)**

Quando se fornece os dados independentes, pode-se usar um “wi” diferente para os dados de cada área metropolitana. O mesmo pode ser feito para os dados de treinamento dependentes. Quando for chamado o **GetModel(...)**, o conjunto de dados retornado conterá todos os modelos separados, cada um identificado pelo “wi”. O modelo que foi treinado por dados independentes e dependentes com “wi=1” será rotulado com “wi=1”. O mesmo ocorre para cada “wi”. Agora, usando o(s) modelo(s) para prever um novo valor dependente (por meio de **Predict(...)** ou **Classify(...)**), as previsões serão baseadas no modelo com o mesmo “wi” que os itens de dados independentes. O mesmo é verdadeiro quando se avalia os modelos usando **Accuracy(...)**.

Na verdade, cada interface dentro dos *bundles* de *ML* de produção pode lidar com várias atividades independentes por meio do uso de *work-item-ids*. A figura mostrada a seguir, ilustra esse fluxo de dados.

Interface Myriad

■ ML Supervisionado: Árvores de Decisão (*Learning Trees* com Interface Myriad)



Interface *Myriad* – Conceito

- Um conjunto de padrões incorporados aos *bundles* de *ML* de produção nativos na plataforma;
- Desenhado para executar várias atividades de Aprendizado de Máquina em uma única invocação da interface;
- Isso significa que pode-se invocar um único processo de treinamento, o qual poderá retornar vários modelos;
- Então pode-se fazer uma única previsão em dados desses vários modelos;
- Podendo-se, portanto, avaliar a precisão de todos os modelos com uma única chamada para a função *Accuracy*;
- Utiliza melhor os recursos do *cluster* da plataforma *HPCC Systems*;
- Executando as atividades ao mesmo tempo, permite aproveitar totalmente o paralelismo do *cluster* da plataforma *HPCC Systems*, realizando todas as atividades em uma única invocação;
- Em contraste com a execução serial, onde muitos nós podem ficar ociosos para qualquer atividade;
- A interface *Myriad* permite que todas as atividades sejam balanceadas em todos os nós do *cluster*;
- Além disso, a interface *Myriad* fornece sincronização mais eficiente, necessária para muitos algoritmos de *Machine Learning*.

RoadMap 04 - Sequência dos códigos ECL:

- ML - Interface *Myriad* - ECL codes (*Target* = Thor | Códigos 10 e 11, compilar *Target* = hThor & Roxie):

1. modProperty.ecl
2. BWR_BrowseData.ecl (submit)
3. isCleanFilter.ecl
4. CleanProperty.ecl
5. modPrepData.ecl
6. BWR_ViewData1.ecl (submit)
7. modSegConvData.ecl
8. BWR_ViewData2.ecl (submit)
9. BWR_TrainReg.ecl (submit)
10. fn_MyriadGetPriceReg.ecl (compile em hThor & Roxie)
11. fn_MyriadGetPriceReg_Web.ecl (compile em hThor & Roxie)
12. BWR_TestQueriesReg.ecl (submit)

Minicurso: Agenda

✓ LexisNexis Risk Solutions: A Empresa

- ✓ Quem somos nós?
- ✓ A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

✓ HPCC Systems: Visão Geral

- ✓ Apresentação de conceitos;
- ✓ Aplicação de conhecimentos;
- ✓ Desenvolvimento de um serviço de consulta;
- ✓ Utilização de algoritmos de Aprendizado de Máquina.

➤ Atividades de treinamento

- Cursos *online*;
- Projetos de pesquisa;
- Oportunidades profissionais.

➤ Considerações Finais

Atividades de treinamento

- **Cursos online: +170 aulas (<https://learn.lexisnexis.com/hpcc>)**

- Introdução ao ECL (parte 1)

- Conceitos e consultas

- Introdução ao ECL (parte 2)

- ETL com ECL

- ECL Avançado (parte 1)

- Dados relacionais

- ECL Avançado (parte 2)

- Superarquivos, XML/JSON e PLN

- ECL Aplicado

- Geração e automação de código ECL

- ROXIE ECL (parte 1)

- Índices e consultas

- ROXIE ECL (parte 2)

- Otimização de consultas

- Machine Learning com HPCC Systems*

- Fundamentos para uso dos *plugins*

- Administração de Sistemas

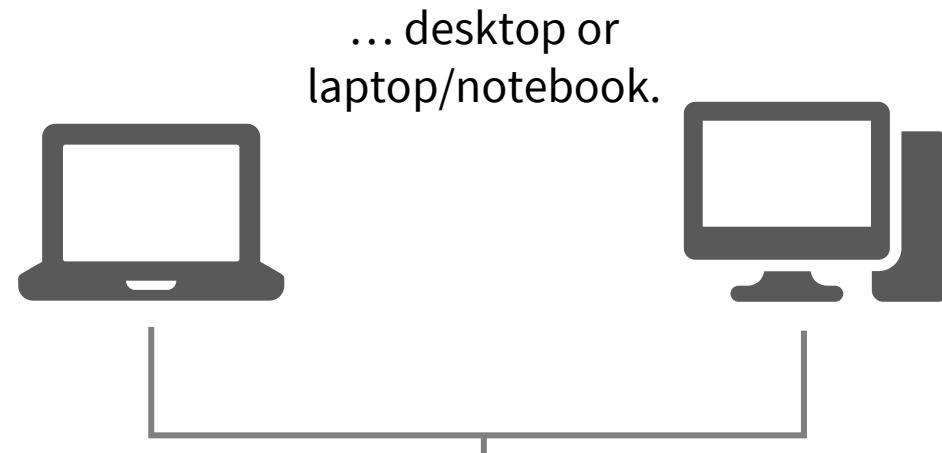
- Conceitos e operação básica

- HPCC para gestores

- Visão geral e aplicações da plataforma

Atividades de treinamento

- **Opções de utilização:** *Playground* (<https://play.hpccsystems.com:18010/>)



HPCC SYSTEMS

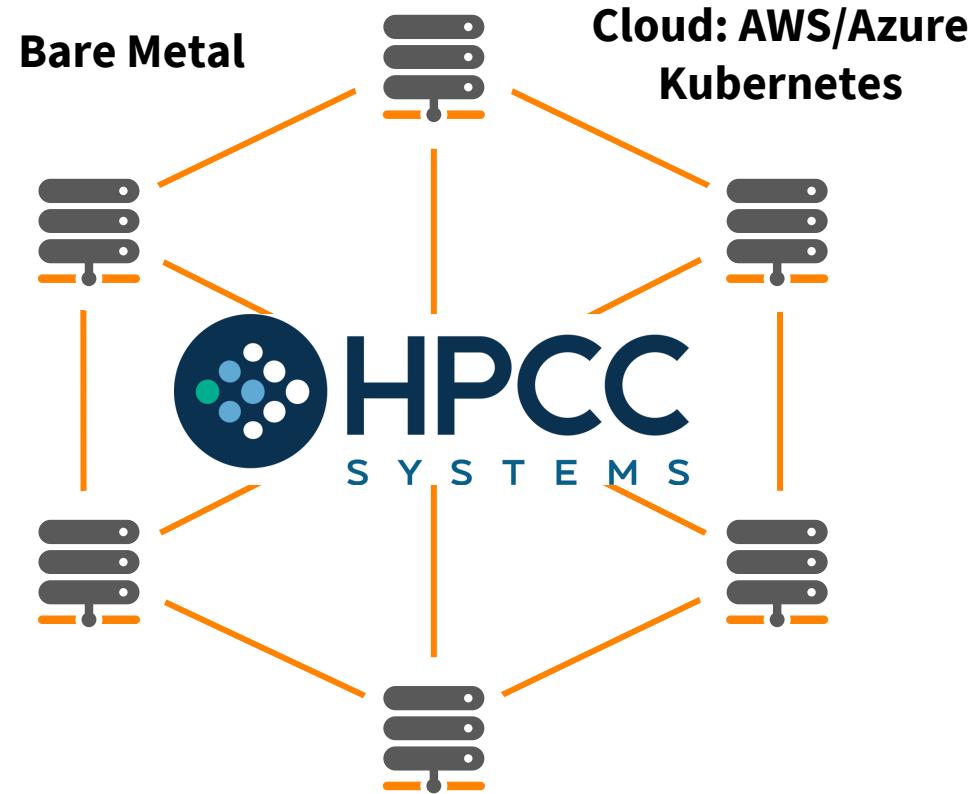
Oracle Virtual Box
HyperV

Docker Desktop
Kubernetes/Helm

GitPod/ONA
GitHub Codespaces

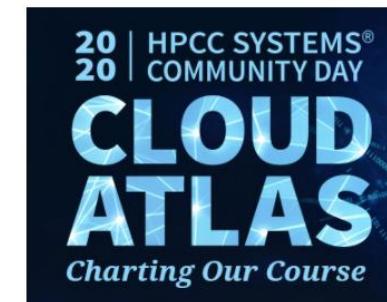


... a cluster with nodes working together as a single entity.



Atividades de treinamento

- Relacionamento com a Comunidade Acadêmica:
<https://hpccsystems.com/community/academics>



Universidade de São Paulo
Brasil



UFPA

Atividades de treinamento

■ Universidades Brasileiras

Universidade de São Paulo
Brasil



UFPA



- Disciplina Optativa na Poli/USP ([Link](#))
- Cursos de difusão (Fundação Vanzolini)
- Co-Orientação de IC's ([Link](#))
- Co-Orientação de TCC's
- Co-Orientação de IC's
- Co-Orientação de TCC's
- Co-Orientação de Mestrado
- Co-Autoria de artigos científicos
- Subsídios para aquisição de equipamentos
- Cursos de difusão

Minicurso: Agenda

✓ LexisNexis Risk Solutions: A Empresa

- ✓ Quem somos nós?
- ✓ A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

✓ HPCC Systems: Visão Geral

- ✓ Apresentação de conceitos;
- ✓ Aplicação de conhecimentos;
- ✓ Desenvolvimento de um serviço de consulta;
- ✓ Utilização de algoritmos de Aprendizado de Máquina.

➤ Atividades de treinamento

- ✓ Cursos *online*;
- Projetos de pesquisa;
- Oportunidades profissionais.

➤ Considerações Finais

Atividades de treinamento

- **Projetos de pesquisa**



Saiba mais em: <https://wiki.hpccsystems.com/display/hpcc/Available+Projects>

Minicurso: Agenda

✓ LexisNexis Risk Solutions: A Empresa

- ✓ Quem somos nós?
- ✓ A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

✓ HPCC Systems: Visão Geral

- ✓ Apresentação de conceitos;
- ✓ Aplicação de conhecimentos;
- ✓ Desenvolvimento de um serviço de consulta;
- ✓ Utilização de algoritmos de Aprendizado de Máquina.

➤ Atividades de treinamento

- ✓ Cursos *online*;
- ✓ Projetos de pesquisa;
- Oportunidades profissionais.

➤ Considerações Finais

Atividades de treinamento

▪ Oportunidades profissionais

#ExploreMore

<https://risk.lexisnexis.com/about-us/careers>
<https://www.linkedin.com/company/lexisnexis-risk-solutions/>
<https://www.vagas.com.br/>

Links Úteis

- Site principal: hpccsystems.com
- Primeiros passos: hpccsystems.com/Why-HPCC-Systems
- Canal do youtube: youtube.com/user/HPCCSystems
- Fórum da Comunidade: hpccsystems.com/forums
- Poster Competition: [Link](#)



Faça parte da Comunidade

Registre-se em:
<https://hpccsystems.com/community/>

LexisNexis Risk Solutions – Equipe de Treinamento

Contatos



- **Mauro D. Marques** – Engenheiro de SW na LexisNexis Risk Solutions
Mauro.Marques@lexisnextrisk.com



- **Alysson R. Oliveira** – Engenheiro de SW na LexisNexis Risk Solutions
Alysson.Oliveira@lexisnextrisk.com

Minicurso: Agenda

✓ LexisNexis Risk Solutions: A Empresa

- ✓ Quem somos nós?
- ✓ A nossa tecnologia: A evolução da plataforma *HPCC Systems*...

✓ HPCC Systems: Visão Geral

- ✓ Apresentação de conceitos;
- ✓ Aplicação de conhecimentos;
- ✓ Desenvolvimento de um serviço de consulta;
- ✓ Utilização de algoritmos de Aprendizado de Máquina.

✓ Atividades de treinamento

- ✓ Cursos *online*;
- ✓ Projetos de pesquisa;
- ✓ Oportunidades profissionais.

➤ Considerações Finais

CONSIDERAÇÕES FINAIS



**PERGUNTAS
& RESPOSTAS**

Material complementar

LexisNexis Risk Solutions: A Corporação



Saiba mais em: <https://risk.lexisnexis.com/group/our-brands>

O Grupo RELX



RELX é um provedor global de análises baseadas em informações e ferramentas de decisão para clientes profissionais e empresariais. O Grupo atende clientes em mais de 180 países e possui escritórios em cerca de 40 países, com um total que supera 36 mil colaboradores.

Saiba mais em www.relx.com



Científico



ELSEVIER

Eventos



Análise de Risco



Legal & Professional



LexisNexis Risk Solutions: A estrutura no Brasil



Área de atuação

Análise de dados para organizações que buscam gerenciar riscos, encontrar oportunidades e melhorar seus resultados. Sediada em Atlanta, Geórgia, a LexisNexis Risk Solutions tem mais de 15.000 funcionários ao redor do mundo.

Tecnologia de código aberto

Plataforma de computação de *Big Data* de código aberto chamada *HPCC Systems* com vastos ativos de dados para proporcionar inteligência de decisão para clientes.

Histórico: Mais de quarenta anos de experiência em *Big Data*...

...Preenchendo a “lacuna de dados”.

Começou em 1973 como Mead Data Central e lançou o serviço Lexis®, pioneiro na pesquisa jurídica on-line, permitindo que os advogados pesquisem bancos de dados de jurisprudência no escritório por meio de uma rede privada de telecomunicações.

Adquirida pela Reed Elsevier em 1994. A Reed Elsevier é fornecedora líder mundial de informações profissionais e soluções de fluxo de trabalho nos setores científico, médico, jurídico e de gerenciamento de risco e negócios.

Hoje, a LexisNexis tem bilhões de documentos e registros pesquisáveis de mais de 45.000 fontes de informação. Sede: Nova York, NY (Jurídico e Profissional) e Alpharetta, GA (Soluções de Risco). Alcance global: clientes em mais de 100 países com cerca de 15.000 funcionários globais.

A LexisNexis Risk Solutions é líder no fornecimento de informações essenciais que ajudam empresas de todos os setores e governos a prever, avaliar e gerenciar riscos. Formada em 2000, a unidade de negócios expandiu através do crescimento orgânico e de quatro aquisições (RiskWise, Dolan, Seisint, ChoicePoint). As principais capacidades da unidade de negócios são dados, linking e data analytics para os clientes em organizações empresariais (serviços financeiros, seguradoras, governo, aplicação da lei).

HPCC Systems: Ativos e Clientes

Unidade	Símbolo	Número de Bytes
Kilobyte	KB	$2^{10} = 1024$ bytes
Megabyte	MB	$2^{20} = 1,048,576$ bytes
Gigabyte	GB	$2^{30} = 1,073,741,824$ bytes
Terabyte	TB	$2^{40} = 1,099,511,627,776$ bytes
Petabyte	PB	$2^{50} = 1,125,899,906,842,624$ bytes
Exabyte	EB	$2^{60} = 1,152,921,504,606,846,976$ bytes
Zettabyte	ZB	$2^{70} = 1,180,591,620,717,411,303,424$ bytes
Yottabyte	YB	$2^{80} = 1,208,925,819,614,629,174,706,176$ bytes

- cerca de **6 petabytes** de dados de mais de 45.000 fontes globais
- mais de **90 milhões** de operações processadas em todo o mundo por hora
- clientes em mais de **100 países**
- **76%** de todas as empresas Fortune 500
- **8** dos 10 principais bancos do mundo
- **100%** dos 50 maiores bancos americanos
- **95** das 100 maiores seguradoras
- **7.500** orgãos governamentais: locais, estaduais e federais

Apresentação de conceitos

BIG DATA

- Os cinco V's:
 - Volume
 - Variedade
 - Velocidade
 - Veracidade
 - Valor

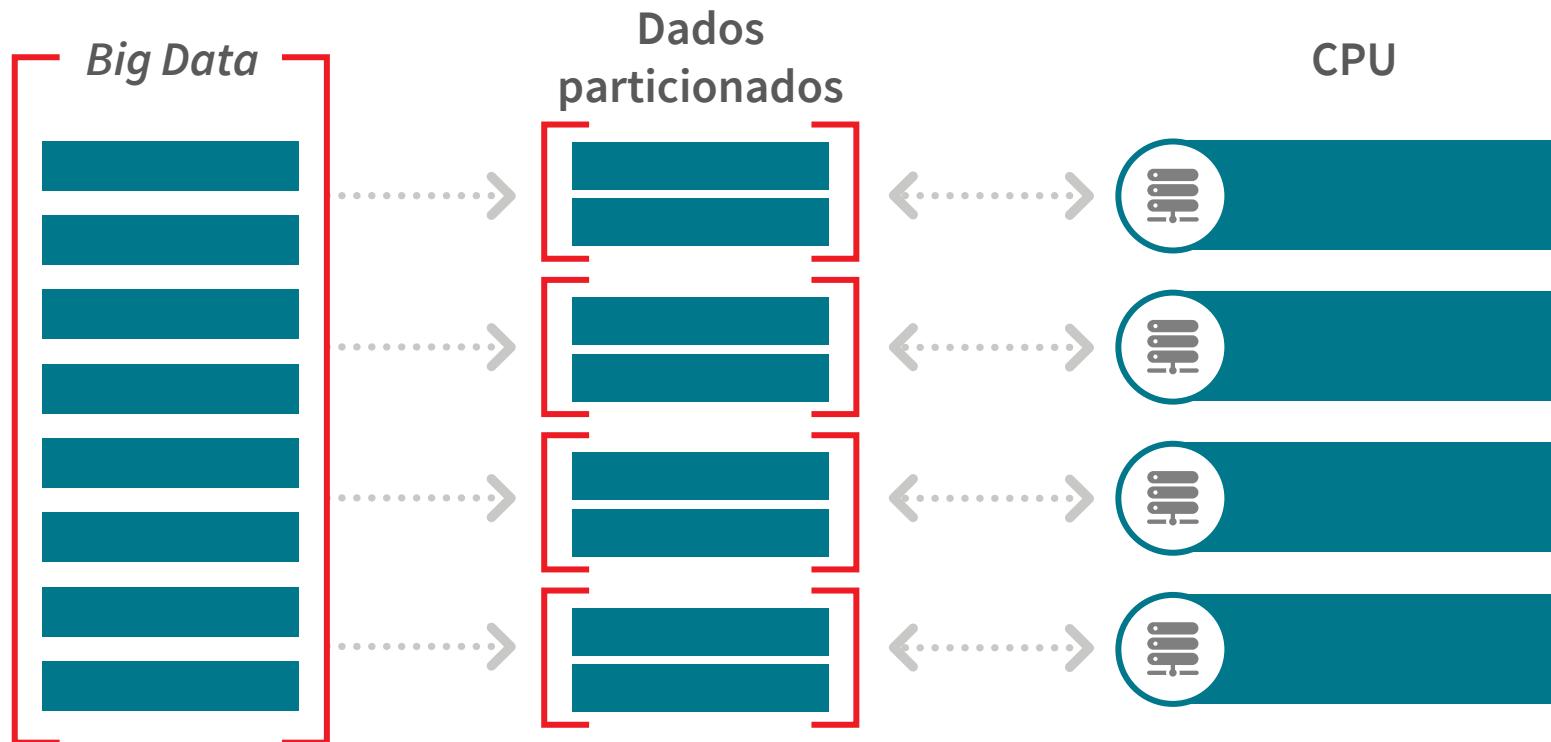


Trade Off do Big Data

- Problema N^2
- Quantidade de dados X Recursos computacionais
- Como processar bilhões de registros em segundos?
- Como analisar múltiplas fontes de dados e transformá-las em informação e conhecimento?

Saiba mais em: <https://www.internetlivestats.com/>

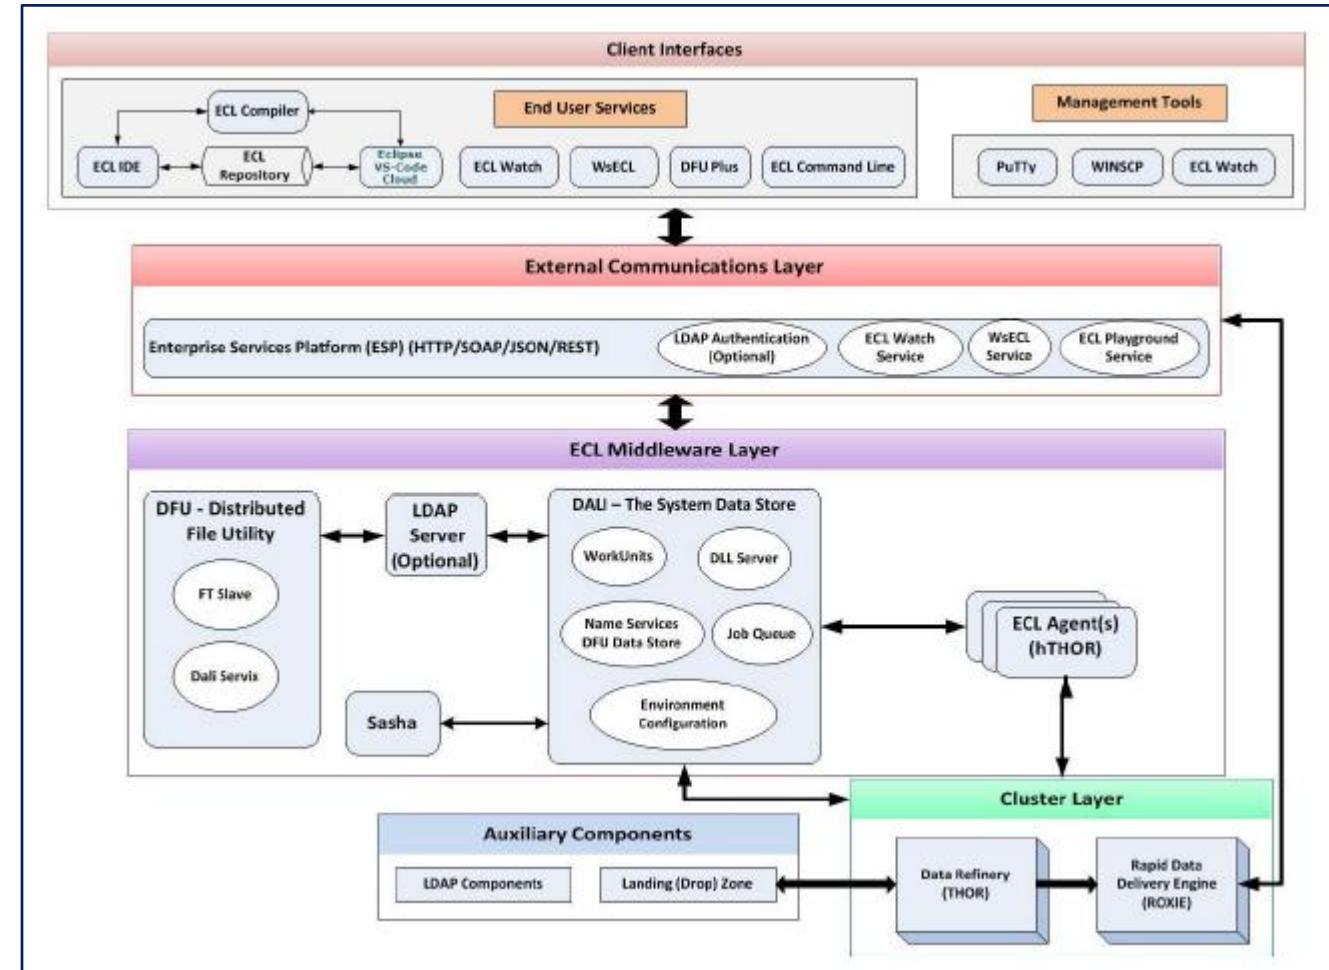
Dados distribuídos e Processamento paralelo



Arquitetura da plataforma HPCC Systems

Componentes da plataforma *HPCC Systems*:

- *Clusters*:
 - Thor
 - Roxie
 - hThor (Agente ECL)
- *Middleware – Servidores de sistema*:
 - DFU
 - ESP
 - ECLCC
 - Dali
 - Sasha
- Outros servidores:
 - Agente ECL (hThor)
 - LDAP
- Interfaces de usuário (*client*):
 - ECL IDE
 - ECL Watch
 - CLI - Command line tools



“Stack” tecnológico da plataforma *HPCC Systems*



Cluster Thor

ETL: Extração, Transformação e Carregamento de dados



Cluster ROXIE

Entrega online de consultas em *Big Data*



Ferramentas para manipulação de dados

Perfilamento, limpeza, consolidação de dados



Bibliotecas de *Machine Learning*

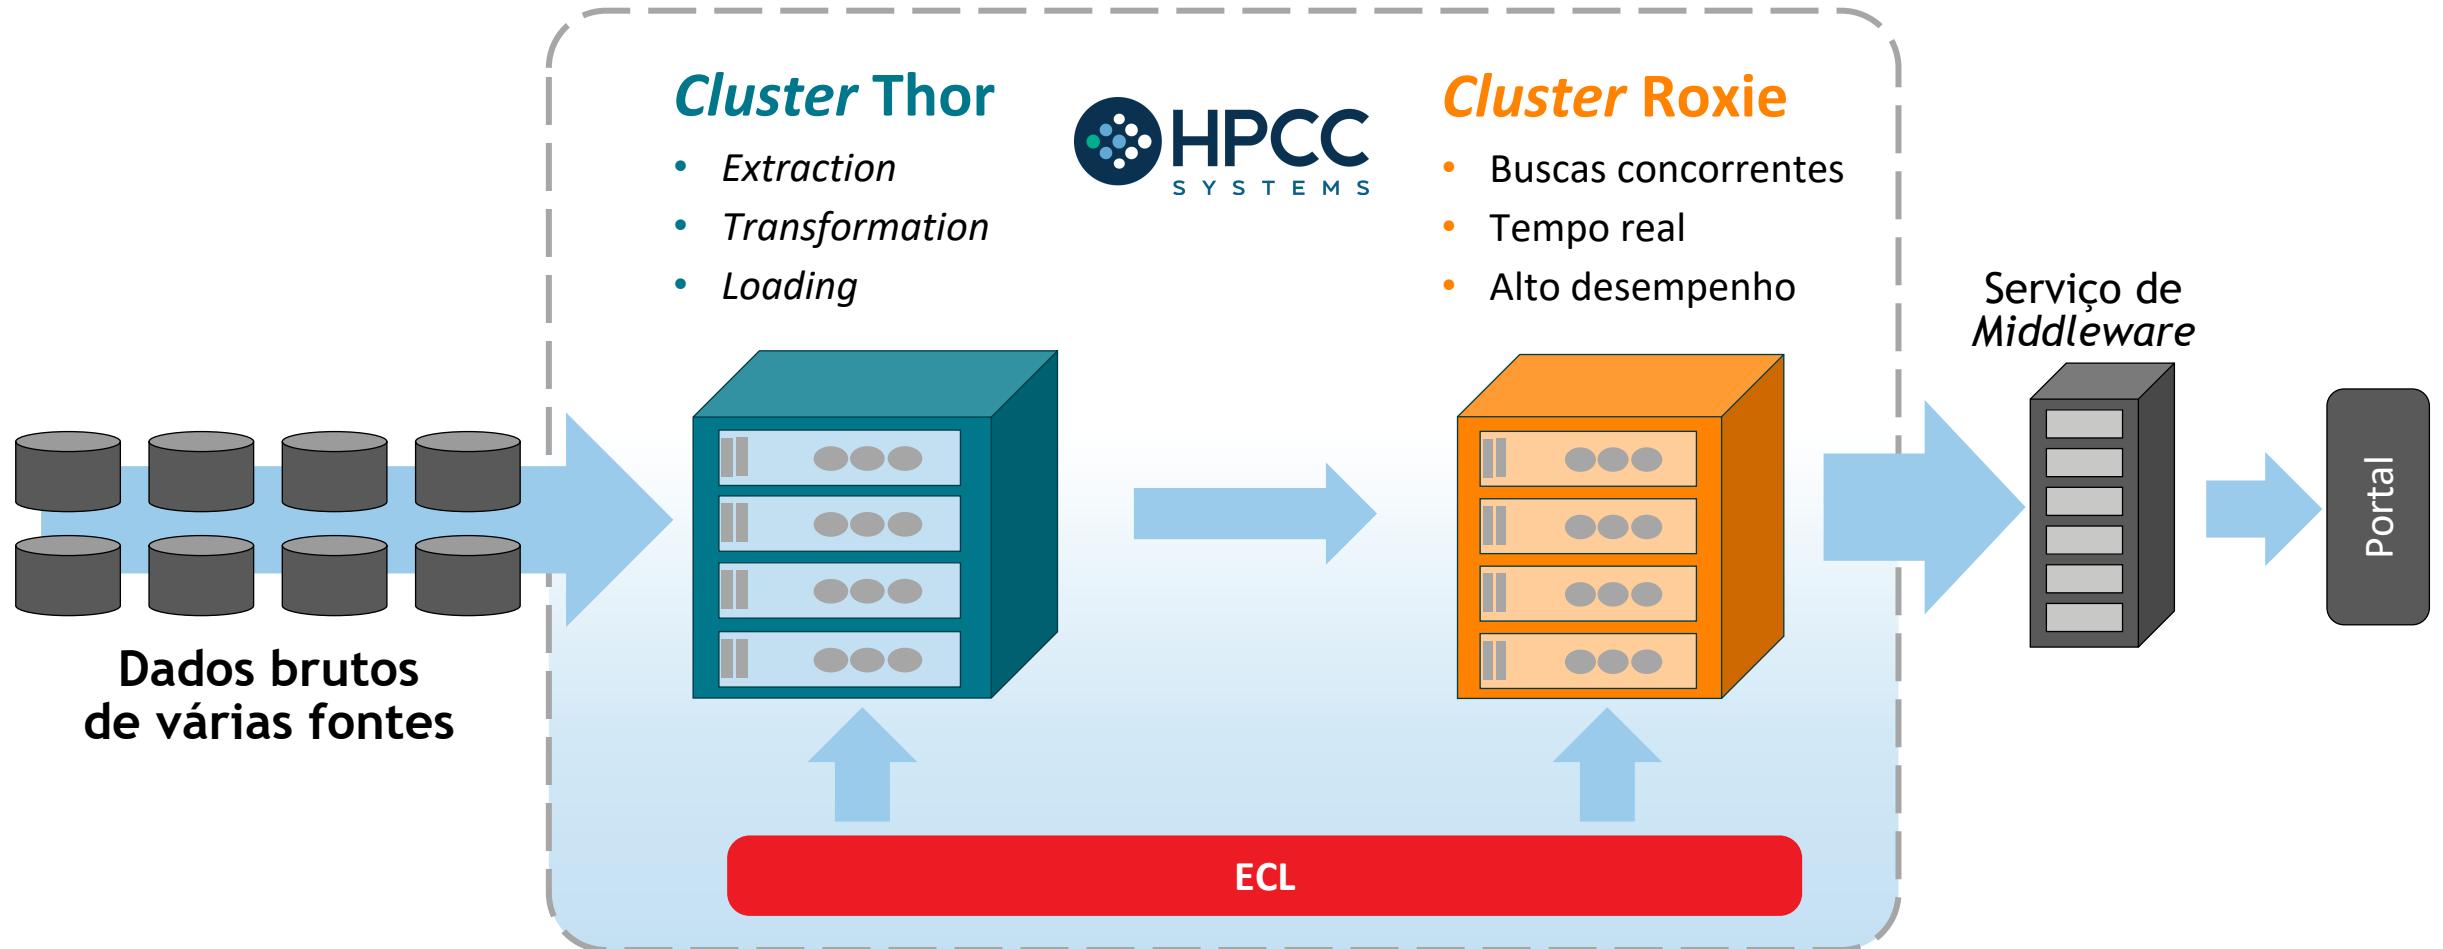
Supervisionado, não-supervisionado, aprendizagem profunda



Conectividade

Plugins de integração com outros sistemas

O Power Trio da plataforma: Thor, Roxie e ECL



Thor e Roxie: Objetivos específicos

Thor:
“Identificar e catalogar todos os seres vivos nos oceanos”



ROXIE:
“Disponibilizar todas as informações sobre uma espécie”



Enterprise Control Language (ECL)

Linguagem de programação centrada em dados (*Data Flow*)

- Declarativa e não-procedural
- Códigos menores e reutilizáveis
- Biblioteca para manipulação de dados

Compilador

- Gera código otimizado (C++)
- Lógica para processamento paralelo e distribuído

Como fazer



vs.



O que fazer

B) Enterprise Control Language (ECL)

Sintaxe completa de uma Definição ECL

Nome := Expressão ;

[Escopo] [TipoValor] Nome [(parâmetros)] := Expressão [:ServiçoWorkflow] ;

EXPORT
BOOLEAN
IsLeapYear
(INTEGER2 year)
year % 4 = 0 AND (year % 100 != 0 OR year % 400 = 0)
: STORED('LeapYearValue');

Atividades de treinamento

■ Treinamento e Suporte



Fácil de
Atualizar



Fácil de
Aprender

HPCC Systems: It's easier.



Fácil de
Programar



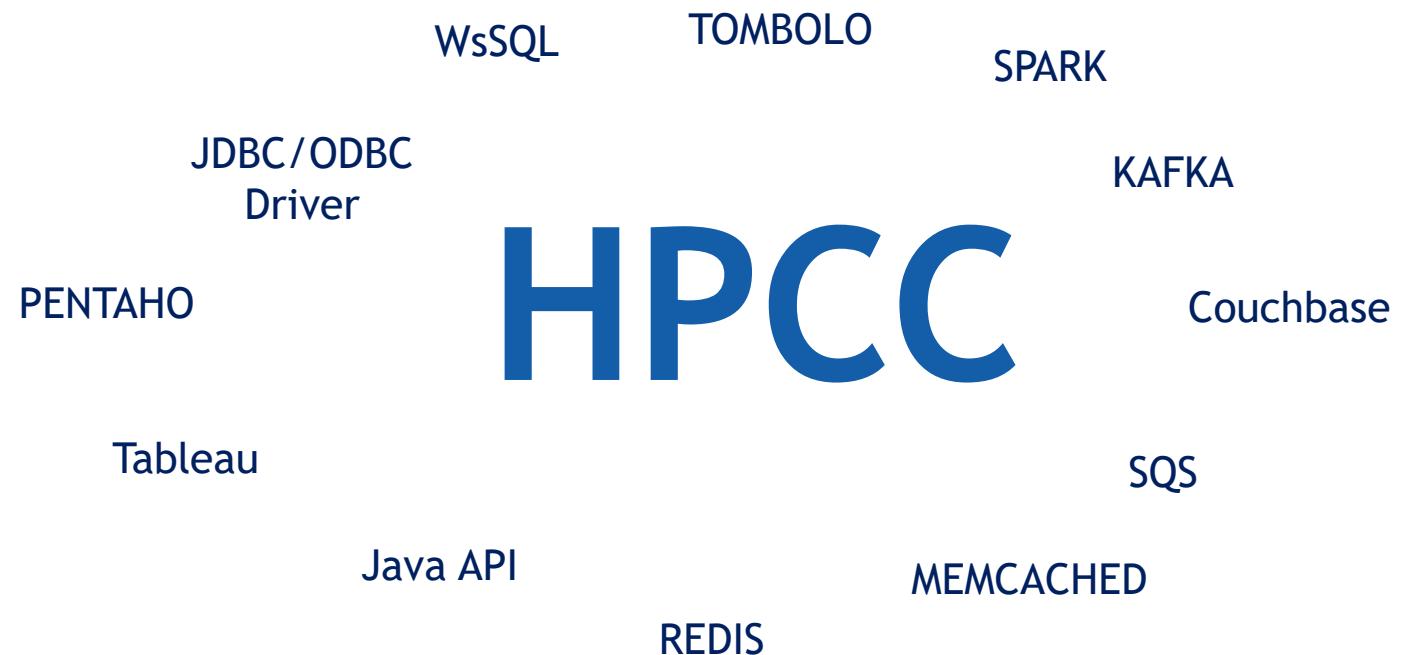
Fácil para
Integração de Dados



Fácil para
Gerenciamento de Clusters

Conectividade

▪ *Plugins*



Linguagens suportadas

■ Exemplos

- C++
- Java
- R
- Cassandra
- Python
- SQL/SqLite

```
CODE: SELECT ALL
IMPORT java;
STRING jcat(STRING a, STRING b) :=
  IMPORT(java,
    'JavaCat.cat:(Ljava/lang/String;Ljava/lang/String;)Ljava/lang/String;' :
  classpath('/opt/HPCCSystems/classes'));

jcat('Hello ', 'world!');
```

```
CODE: SELECT ALL
IMPORT python;
SET OF STRING split(STRING text) := EMBED(python)
  return text.split()
ENDEMBED;
split('Once upon a time');
```

```
CODE: SELECT ALL
IMPORT python;
r := RECORD
  STRING word;
  UTF8 tags;
END;
DATASET(R) tag(STRING text) := IMPORT(python, './ex2.tag');
tag('Once upon a time there was a boy called Richard');
```

```
CODE: SELECT ALL
IMPORT MySQL;
stringrec := RECORD
  string name
END;
sqlrec := RECORD
  string ssn;
  string address;
END;
DATASET(sqlrec) MySQLJoin(dataset(stringrec) inrecs) := EMBED(mysql)
  SELECT * from tbl1 where name = ?;
ENDEMBED;
MySQLJoin(indata);
```



LexisNexis®
RISK SOLUTIONS